

MCDI504

MACHINE LEARNING I

INFORME FINAL DE PROYECTO — FASES 2 Y 3: DESARROLLO DEL PROYECTO

Integrantes: Enzo Pinilla · Claudio Alarcón · Luis Rodrigo Espinoza

Curso: MCDI504 - Machine Learning I

Docente: David Ruete Zúñiga

Grupo: 2

Fecha: 23 de agosto de 2026

Repositorio: https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

I. Tabla de contenido

I.	<i>Tabla de contenido</i>	2
II.	<i>Descripción del conjunto de datos y preparación analítica para regresión supervisada</i>	3
III.	<i>Implementación del modelo de regresión supervisada</i>	4
IV.	<i>Ajuste de hiperparámetros del modelo de regresión</i>	5
V.	<i>Evaluación desempeño mediante métricas de regresión</i>	6
VI.	<i>Comparación técnica entre modelos de regresión</i>	7
VII.	<i>Descripción del conjunto de datos y preparación para clasificación</i>	8
VIII.	<i>Análisis exploratorio inicial del conjunto de datos</i>	8
IX.	<i>Notebook F3_RedesNeuronales.ipynb y documentación del proceso</i>	10
X.	<i>Red neuronal con una capa oculta</i>	11
XI.	<i>Red neuronal con dos capas ocultas</i>	12
XII.	<i>Red neuronal con tres capas ocultas</i>	13
XIII.	<i>Desempeño de redes neuronales</i>	15
XIV.	<i>Comparación de arquitecturas de redes neuronales</i>	15
XV.	<i>Conclusiones</i>	16
XVI.	<i>Referencias</i>	16
XVII.	<i>Anexos</i>	17
	Anexo A. Fragmentos esenciales de código	17
	Anexo B. Configuraciones destacadas de GridSearchCV	17
	Anexo C. Matrices de confusión en formato tabulado	17

II. Descripción del conjunto de datos y preparación analítica para regresión supervisada

El informe integra las Fases 2 y 3 sobre el dataset Titanic. Para cubrir el objetivo de regresión de RA2 con el mismo conjunto de datos, se define fare como variable objetivo continua. Esta decisión permite mantener continuidad del caso y separar claramente la tarea de regresión de la tarea de clasificación de supervivencia. La preparación sigue un flujo reproducible de selección de variables, imputación, transformación y partición entrenamiento/prueba (Ruete Zúñiga, 2026a).

Elemento	Definición aplicada
Dataset	Titanic, 891 observaciones y 15 variables en la carga original.
Variable objetivo continua	fare: tarifa pagada por el pasajero.
Predictores	pclass, sex, age, sibsp, parch y embarked.
Tratamiento de age	Imputación con mediana (28 años).
Tratamiento de embarked	Imputación con la moda (S).
Transformación	One-hot encoding para sex y embarked; escalamiento dentro del pipeline de SVR.
Partición	80% entrenamiento / 20% prueba, random_state=42.
Tamaños	X_train=(712, 7); X_test=(179, 7).

Justificación técnica. Se excluyen de la regresión survived y variables redundantes o derivadas, porque el propósito es estimar una magnitud económica disponible antes de observar el resultado de supervivencia. La mediana reduce sensibilidad a valores extremos en age; la moda es apropiada para los dos valores faltantes de embarked; y la codificación one-hot evita imponer un orden artificial a categorías nominales.




Figura 1. Distribución de la variable objetivo continua fare.

La tarifa es fuertemente asimétrica: la mediana es 14.45, mientras el máximo alcanza 512.33. Dada esta dispersión, el análisis compara modelos lineales y no lineales y evalúa sus errores fuera de muestra.

III. Implementación del modelo de regresión supervisada

Se implementan cuatro configuraciones iniciales para construir una línea base comparativa: regresión lineal múltiple, árbol de decisión, Random Forest y Support Vector Regression (SVR). La regresión lineal aporta interpretabilidad; los árboles permiten relaciones no lineales; Random Forest reduce la varianza mediante ensamble; y SVR modela relaciones no lineales mediante una función kernel. La implementación se realiza con scikit-learn, manteniendo el mismo conjunto de prueba para todos los modelos (Pedregosa et al., 2011).

Modelo	Configuración inicial	Justificación
Regresión lineal múltiple	Parámetros por defecto	Línea base interpretable y de baja complejidad.
Árbol de decisión	max_depth=5; random_state=42	Permite no linealidad y controla profundidad.
Random Forest	200 árboles; max_depth=8; min_samples_leaf=2	Ensamble no lineal con control de complejidad.
SVR inicial	C=1; epsilon=0.1; gamma=scale + StandardScaler	Modelo kernel sensible a escala; candidato a ajuste.

Modelo	MSE	RMSE	R ²
Regresión lineal múltiple	928.613	30.473	0.3999
SVR inicial	1142.366	33.799	0.2618
Random Forest	1370.924	37.026	0.1141
Árbol de decisión	1515.252	38.926	0.0208

Resultados iniciales. La regresión lineal múltiple es la mejor línea base entre las configuraciones iniciales por RMSE. El SVR inicial presenta un error mayor, por lo que se selecciona para la búsqueda de hiperparámetros, dado que su comportamiento depende de C, epsilon y gamma.

IV. Ajuste de hiperparámetros del modelo de regresión

El ajuste se realiza mediante GridSearchCV con validación cruzada de 5 particiones aplicada únicamente al conjunto de entrenamiento. La métrica de selección es RMSE: se evalúan 4 valores de C, 4 valores de epsilon y 2 configuraciones de gamma, para un total de 32 combinaciones. El conjunto de prueba no participa en la selección de hiperparámetros, lo que preserva una evaluación final independiente (scikit-learn Developers, s. f.-a).

Hiperparámetro	Valores evaluados	Función
C	1, 10, 50, 100	Controla la penalización de errores y la regularización.
epsilon	0.05, 0.1, 0.5, 1.0	Define el margen de tolerancia de error en SVR.
gamma	scale, auto	Controla el alcance del kernel RBF.
Validación	5-fold CV	Compara configuraciones en entrenamiento.

C	epsilon	gamma	RMSE CV	Rango
100	0.1	scale	36.103	1
100	0.1	auto	36.103	1
100	0.05	auto	36.103	3
100	0.05	scale	36.103	4
100	0.5	scale	36.122	5
100	0.5	auto	36.122	5
100	1.0	scale	36.164	7
100	1.0	auto	36.164	8

Configuración seleccionada: C=100, epsilon=0.1 y gamma='scale', con RMSE promedio de validación cruzada de 36.103. La selección se fundamenta en el menor error medio observado durante la búsqueda, no en el desempeño del conjunto de prueba.

V. Evaluación desempeño mediante métricas de regresión

La evaluación final utiliza MSE, RMSE y R^2 . MSE penaliza fuertemente los errores grandes; RMSE devuelve el error a las unidades de fare; R^2 expresa la proporción de variabilidad explicada respecto de una predicción basada en la media. Las tres métricas se calculan sobre las 179 observaciones reservadas para prueba.

Modelo	MSE	RMSE	R^2
SVR ajustado	640.287	25.304	0.5862
Regresión lineal múltiple	928.613	30.473	0.3999
SVR inicial	1142.366	33.799	0.2618
Random Forest	1370.924	37.026	0.1141
Árbol de decisión	1515.252	38.926	0.0208




Figura 2. Comparación de RMSE en los modelos de regresión.

El SVR ajustado obtiene $MSE=640.287$, $RMSE=25.304$ y $R^2=0.5862$, el mejor resultado del conjunto evaluado. Un R^2 de 58.62% indica capacidad explicativa moderada: el modelo mejora de manera clara respecto de las líneas base, pero aún queda variabilidad de fare no explicada por los predictores seleccionados.




Figura 3. SVR ajustado: tarifa real frente a tarifa predicha.

VI. Comparación técnica entre modelos de regresión

Modelo	Fortalezas	Limitaciones	Decisión
SVR ajustado	Menor RMSE y mayor R^2 ; modela relaciones no lineales.	Menor interpretabilidad; sensible a la escala y a la configuración de hiperparámetros.	Seleccionado preliminarmente.
Regresión lineal	Interpretable, rápida y sólida como baseline.	Supone relación lineal y es sensible a extremos.	Baseline principal.
Random Forest	Captura interacciones y no linealidad; robusto a escalas.	En esta configuración no supera al baseline lineal; mayor complejidad.	Alternativa no seleccionada.
Árbol de decisión	Reglas interpretables y no lineales.	Desempeño débil en prueba y sensibilidad a profundidad.	No seleccionado.

Selección final de Fase 2. Se conserva SVR ajustado como modelo de regresión más pertinente para este experimento por su menor RMSE y mayor R^2 . La selección es empírica y específica a la partición y a las variables incluidas; no implica una relación causal entre características del pasajero y la tarifa.

VII. Descripción del conjunto de datos y preparación para clasificación

Para la clasificación supervisada se utiliza survived como variable objetivo binaria: 0 = no sobrevivió y 1 = sobrevivió. Se aplica la preparación del notebook docente de Fase 3: eliminación de columnas redundantes o con alta ausencia, imputación de age y embarked, codificación de sex y embarked, partición 80/20 y escalamiento mediante StandardScaler para las redes neuronales (Ruete Zúñiga, 2026b).

Elemento	Preparación para clasificación
Objetivo	survived (0/1).
Predictores finales	pclass, age, sibsp, parch, fare, sex_male, embarked_Q, embarked_S
Columnas eliminadas	deck, class, who, adult_male, embark_town, alive, alone
age	177 faltantes imputados con mediana = 28.
embarked	2 faltantes imputados con moda = S.
Codificación	One-hot encoding con drop_first=True.
Partición	Entrenamiento 712 / prueba 179 (80/20), random_state=42.
Escalamiento	StandardScaler ajustado solo con X_train y aplicado a X_test.

Justificación técnica. El escalador se ajusta exclusivamente con datos de entrenamiento para evitar fuga de información. Todas las arquitecturas MLP reciben exactamente los mismos datos escalados, de modo que la comparación se centra en la estructura de capas ocultas.

VIII. Análisis exploratorio inicial del conjunto de datos

Clase	Código	Frecuencia	Porcentaje
No sobrevivió	0	549	61.62%
Sobrevivió	1	342	38.38%




Figura 4. Distribución de la variable objetivo survived.

Se observa un desbalance moderado: 61,62% de la muestra corresponde a no sobrevivientes y 38,38% a sobrevivientes. Por ello, el análisis complementa Accuracy con Precision, Recall, F1-score y matrices de confusión para evaluar el desempeño sobre la clase positiva.




Figura 5. Valores faltantes antes del preprocesamiento.

Los faltantes se concentran en deck (688), age (177), embark_town (2) y embarked (2). deck se elimina por su elevada ausencia; age y embarked se imputan porque conservan información útil con una proporción de faltantes mucho menor.




Figura 6. Tasa descriptiva de supervivencia por sexo.




Figura 7. Tasa descriptiva de supervivencia por clase de pasaje.

Patrones observados. La tasa de supervivencia difiere de forma visible por sexo y por clase de pasaje, lo que sugiere que variables como `sex_male` y `pclass` contienen información discriminante. Esta evidencia es descriptiva, no causal. La transformación a variables numéricas y el escalamiento responden directamente a las necesidades del MLP.

IX. Notebook F3_RedesNeuronales.ipynb y documentación del proceso

El notebook final se denomina `F3_RedesNeuronales.ipynb` y está organizado en un flujo único que integra regresión (Fase 2) y clasificación mediante redes neuronales (Fase 3). Incluye celdas narrativas, código ejecutable, salidas tabuladas, gráficos, semilla de reproducibilidad y correspondencia explícita con este informe.

Etapas	Evidencia en notebook	Apartado informe
Carga y revisión	Carga de Titanic, dimensiones y faltantes	II, VII, VIII
Regresión - preparación	fare, predictores, imputación, encoding, split	II
Regresión - modelos	LinearRegression, DecisionTreeRegressor, RandomForestRegressor, SVR	III
Regresión - tuning	GridSearchCV sobre SVR	IV
Regresión - evaluación	MSE, RMSE, R ² y comparación	V-VI
Clasificación - preparación	survived, limpieza, encoding, split, StandardScaler	VII-VIII
MLP 1/2/3 capas	MLPClassifier con arquitecturas del notebook docente	X-XII
Evaluación MLP	Matrices, Accuracy, Precision, Recall, F1	XIII-XIV
Conclusiones	Síntesis integrada Fases 2 y 3	XV

Repositorio del grupo: https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

Archivos y rutas considerados en la entrega: /notebooks/F3_RedesNeuronales.ipynb, /figures/, /reports/f3_s03_grupo2.pdf, README.md y archivo de dependencias/versiones.

X. Red neuronal con una capa oculta

Arquitectura utilizada: (100,). El modelo emplea activación ReLU, optimizador Adam, max_iter=500 y random_state=42, sobre X_train escalado. Esta configuración reproduce la estructura del notebook docente para mantener comparabilidad entre las tres arquitecturas (Ruete Zúñiga, 2026b; scikit-learn Developers, s. f.-b).

Parámetro	Valor
hidden_layer_sizes	(100,)
activation	relu
solver	adam
max_iter	500
random_state	42
Iteraciones ejecutadas	500
ConvergenceWarning	Sí

Accuracy	Precision	Recall	F1-score	TN	FP	FN	TP
0.8212	0.8182	0.7297	0.7714	93	12	20	54




Figura 8. Matriz de confusión - MLP 1 capa oculta.

La red de una capa obtiene Accuracy=0.8212 y F1=0.7714. Presenta 20 falsos negativos y alcanza el máximo de 500 iteraciones con advertencia de convergencia. Su principal fortaleza es combinar desempeño competitivo con menor complejidad relativa.

XI. Red neuronal con dos capas ocultas

Arquitectura utilizada: (100, 50). El modelo emplea activación ReLU, optimizador Adam, max_iter=500 y random_state=42, sobre X_train escalado. Esta configuración reproduce la estructura del notebook docente para mantener comparabilidad entre las tres arquitecturas (Ruede Zúñiga, 2026b; scikit-learn Developers, s. f.-b).

Parámetro	Valor
hidden_layer_sizes	(100, 50)
activation	relu
solver	adam
max_iter	500
random_state	42

Parámetro	Valor
Iteraciones ejecutadas	500
ConvergenceWarning	Sí

Accuracy	Precision	Recall	F1-score	TN	FP	FN	TP
0.8156	0.8154	0.7162	0.7626	93	12	21	53




Figura 9. Matriz de confusión - MLP 2 capas ocultas.

La red de dos capas obtiene Accuracy=0.8156 y F1=0.7626 y también alcanza el máximo de iteraciones. En esta partición, la profundidad adicional no produjo una mejora respecto de la arquitectura de una capa.

XII. Red neuronal con tres capas ocultas

Arquitectura utilizada: (100, 50, 25). El modelo emplea activación ReLU, optimizador Adam, max_iter=500 y random_state=42, sobre X_train escalado. Esta configuración reproduce la estructura del notebook docente para mantener comparabilidad entre las tres arquitecturas (Ruete Zúñiga, 2026b; scikit-learn Developers, s. f.-b).

Parámetro	Valor
hidden_layer_sizes	(100, 50, 25)
activation	relu
solver	adam
max_iter	500
random_state	42
Iteraciones ejecutadas	289
ConvergenceWarning	No

Accuracy	Precision	Recall	F1-score	TN	FP	FN	TP
0.8268	0.8116	0.7568	0.7832	92	13	18	56




Figura 10. Matriz de confusión - MLP 3 capas ocultas.

La red de tres capas obtiene Accuracy=0.8268, Recall=0.7568 y F1=0.7832, con 18 falsos negativos. Converge en 289 iteraciones sin advertencia y logra el mejor balance global entre las arquitecturas evaluadas en esta partición.

XIII. Desempeño de redes neuronales

Modelo	Accuracy	Precision	Recall	F1	Matriz de confusión
MLP 1 capa oculta	0.8212	0.8182	0.7297	0.7714	[[93, 12], [20, 54]]
MLP 2 capas ocultas	0.8156	0.8154	0.7162	0.7626	[[93, 12], [21, 53]]
MLP 3 capas ocultas	0.8268	0.8116	0.7568	0.7832	[[92, 13], [18, 56]]




Figura 11. Comparación de métricas de clasificación por arquitectura MLP.

La arquitectura de tres capas lidera Accuracy, Recall y F1-score; la de una capa alcanza la mayor Precision entre las tres y queda muy cerca en desempeño global. La de dos capas no mejora la arquitectura más simple. Las matrices de confusión muestran que el MLP de tres capas reduce los falsos negativos a 18, frente a 20 y 21 en las otras configuraciones.

XIV. Comparación de arquitecturas de redes neuronales

Arquitectura	Fortalezas	Limitaciones	Lectura para decisión
1 capa (100)	Menor complejidad; Accuracy y F1 competitivos; alta Precision.	500 iteraciones y advertencia de convergencia.	Alternativa parsimoniosa muy competitiva.
2 capas (100,50)	Mayor capacidad representacional.	No mejora métricas; 500 iteraciones y advertencia.	Complejidad adicional sin ganancia observada.
3 capas (100,50,25)	Mayor Accuracy, Recall y F1; menos FN; converge antes de 500.	Mayor complejidad y menor interpretabilidad.	Seleccionada preliminarmente por desempeño global.

Fundamento técnico de la decisión. Se selecciona preliminarmente el MLP de tres capas porque domina tres métricas relevantes y reduce los falsos negativos. Sin embargo, la diferencia absoluta respecto del MLP de una capa es pequeña. Por ello, esta selección se interpreta únicamente dentro de la partición, la configuración y el alcance de la evidencia evaluada en esta entrega.

XV. Conclusiones

- Fase 2: el SVR ajustado fue el modelo de regresión más sólido en la partición de prueba (RMSE=25.304; $R^2=0.5862$), superando a la regresión lineal, árbol, Random Forest y SVR inicial.
- El ajuste de hiperparámetros seleccionó $C=100$, $\epsilon=0.1$ y $\gamma=\text{scale}$; esto evidencia que la configuración paramétrica puede modificar de forma material el desempeño del modelo.
- Fase 3: la preparación de clasificación dejó ocho predictores numéricos sin nulos y escalados para MLP; el desbalance moderado justificó complementar Accuracy con Precision, Recall y F1-score.
- El MLP de tres capas (100, 50, 25) logró el mejor resultado observado (Accuracy=0.8268; Recall=0.7568; F1=0.7832) y redujo los falsos negativos a 18.
- Las decisiones de preparación permitieron trabajar con un conjunto completo y numérico: la imputación conservó observaciones, el one-hot encoding representó las categorías y el escalamiento homogeneizó las variables utilizadas por SVR y MLP.
- La selección final se considera preliminar y corresponde a la configuración y partición utilizadas. Por ello, no permite establecer una superioridad definitiva entre arquitecturas ni establecer relaciones causales a partir del desempeño predictivo.

XVI. Referencias

Las decisiones metodológicas se apoyan en material docente, documentación oficial y literatura académica. Las referencias siguientes cumplen la distribución mínima solicitada y se integran mediante citas en el desarrollo del informe.

- Ruete Zúñiga, D. (2026a). Evaluación Sumativa 2: Informe Final de Proyecto - Fases 2 y 3 [Instrucciones de actividad]. Universidad Andrés Bello.
- Ruete Zúñiga, D. (2026b). fase_3_entregable_semana_3_sumativa.ipynb [Notebook de apoyo docente]. Universidad Andrés Bello.
- scikit-learn Developers. (s. f.-a). GridSearchCV. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- scikit-learn Developers. (s. f.-b). MLPClassifier. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html
- scikit-learn Developers. (s. f.-c). SVR. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVR.html>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An introduction to statistical learning: With applications in Python. Springer.

XVII. Anexos

Anexo A. Fragmentos esenciales de código

```
# Regresión
GridSearchCV(Pipeline([('scaler',
                        StandardScaler()),
                        ('svr',
                         SVR())]),
             param_grid=param_grid,
             scoring='neg_root_mean_squared_error',
             cv=5)

# Clasificación
MLPClassifier(hidden_layer_sizes=(100,
                                  50,
                                  25),
              solver='adam',
              max_iter=500,
              activation='relu',
              random_state=42)
```

Anexo B. Configuraciones destacadas de GridSearchCV

C	epsilon	gamma	RMSE CV	Rango
100	0.1	scale	36.103	1
100	0.1	auto	36.103	1
100	0.05	auto	36.103	3
100	0.05	scale	36.103	4
100	0.5	scale	36.122	5
100	0.5	auto	36.122	5
100	1.0	scale	36.164	7
100	1.0	auto	36.164	8
50	1.0	scale	37.146	9
50	1.0	auto	37.146	10

Anexo C. Matrices de confusión en formato tabulado

Modelo	TN	FP	FN	TP
MLP 1 capa oculta	93	12	20	54
MLP 2 capas ocultas	93	12	21	53
MLP 3 capas ocultas	92	13	18	56