



MCDI504
MACHINE LEARNING I
AVANCE DEL PROYECTO — FASE 4:
EVALUACIÓN Y VALIDACIÓN DEL MODELO

Integrantes: Enzo Pinilla, Claudio Alarcón, Luis Rodrigo Espinoza

Docente: David Ruete Zúñiga

Curso: MCDI504 - Machine Learning I

Grupo: N.2

Fecha: 27 de agosto de 2026

Repositorio del proyecto:

https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

I. Tabla de contenido

I. Tabla de contenido	2
II. Descripción de los modelos y del conjunto de datos para evaluación	3
III. Preparación del proceso de evaluación	4
IV. Notebook F4_Evaluacion.ipynb	5
V. Evaluación de modelos supervisados.....	6
VI. Matriz de confusión y métricas de clasificación	7
VII. Validación cruzada de la red neuronal con una capa oculta	8
VIII. Interpretación comparativa de resultados	10
IX. Justificación metodológica de la evaluación utilizada	11
X. Conclusiones.....	12
XI. Uso de fuentes, citación y referencias	13
XII. Anexos	13

II. Descripción de los modelos y del conjunto de datos para evaluación

Este informe corresponde a la Evaluación Formativa 4 del curso MCDI504 - Machine Learning I, “Avance del Proyecto — Fase 4: Evaluación y Validación del Modelo”. Su propósito es evaluar el desempeño de las redes neuronales tipo MLP desarrolladas en la Fase 3 del proyecto y aplicar validación cruzada a la arquitectura de una capa oculta, de acuerdo con el resultado de aprendizaje RA4 y los indicadores ID4.1 e ID4.2.

2.1 Descripción general del dataset

El caso aplicado utiliza el dataset Titanic, cargado mediante `seaborn.load_dataset("titanic")`, con 891 observaciones. Conforme a la preparación realizada en la Fase 3, se eliminan las columnas redundantes o derivadas de la variable objetivo (deck, class, who, adult_male, embark_town, alive, alone), quedando como predictores pclass, sex, age, sibsp, parch, fare y embarked. Las variables age (177 valores faltantes) y embarked (2 valores faltantes) presentan datos ausentes, que se imputan dentro del pipeline de preprocesamiento utilizando únicamente información del conjunto de entrenamiento.

2.2 Variable objetivo y clase objetivo

La variable objetivo es survived, codificada como 0 = no sobrevivió y 1 = sobrevivió. La clase objetivo (clase positiva) de este análisis es sobrevivió (1), evento de interés del problema de clasificación binaria. El dataset completo presenta un desbalance moderado entre clases: 61,62 % no sobrevivió (549 casos) y 38,38 % sobrevivió (342 casos).




Figura 1. Distribución de clases en el dataset Titanic.

2.3 Modelos considerados en la evaluación

Conforme al alcance de esta fase, los modelos considerados son exclusivamente las tres arquitecturas de red neuronal (MLPClassifier de scikit-learn) desarrolladas y evaluadas en la Fase 3 del proyecto, con activación ReLU, solver Adam, max_iter=500 y random_state=42:

Arquitectura	Configuración	Rol en la evaluación
MLP 1 capa oculta	hidden_layer_sizes=(100,)	Evaluada por Hold-Out y por validación cruzada K-Fold (única arquitectura exigida para CV)
MLP 2 capas ocultas	hidden_layer_sizes=(100, 50)	Evaluada por Hold-Out
MLP 3 capas ocultas	hidden_layer_sizes=(100, 50, 25)	Evaluada por Hold-Out

2.4 Conjunto de prueba utilizado

Las tres arquitecturas se evalúan sobre el mismo conjunto de prueba, obtenido mediante una partición 80/20 estratificada y reproducible (test_size=0.20, stratify=y, random_state=42): 712 observaciones de entrenamiento y 179 de prueba.

2.5 Justificación del uso de métricas de clasificación

Se utilizan accuracy, precision, recall y F1-score porque el problema es de clasificación binaria con clases moderadamente desbalanceadas. El accuracy por sí solo puede sobreestimar el desempeño en presencia de desbalance; precision y recall, calculados sobre la clase sobrevivíó (1), muestran respectivamente la confiabilidad de las predicciones positivas y la capacidad del modelo para detectar sobrevivientes reales, mientras que el F1-score resume ambos aspectos en un solo valor (scikit-learn Developers, s.f.-c).

III. Preparación del proceso de evaluación

El proceso de evaluación se diseñó para evitar fuga de información (data leakage), un problema presente en una versión previa de este análisis, donde la imputación, codificación y escalamiento se ajustaban antes de dividir los datos. El procedimiento corregido sigue este orden: separar X e y; dividir en entrenamiento y prueba; ajustar imputación, codificación y escalamiento solo con el conjunto de entrenamiento, integrados en un Pipeline y un ColumnTransformer de scikit-learn; y aplicar esas mismas transformaciones, ya aprendidas, al conjunto de prueba (scikit-learn Developers, s.f.-a).

3.1 Definición del conjunto de prueba

Elemento	Valor
Método de partición	train_test_split, test_size=0.20, stratify=y, random_state=42
Observaciones de entrenamiento	712
Observaciones de prueba	179
Proporción de clases en entrenamiento	61,66 % clase 0 / 38,34 % clase 1
Proporción de clases en prueba	61,45 % clase 0 / 38,55 % clase 1

La estratificación mantiene aproximadamente la misma proporción de sobrevivientes en ambos conjuntos. Dado el desbalance moderado del dataset, una partición no estratificada podría sobre- o subrepresentar la clase positiva en el conjunto de prueba, distorsionando precision y recall sin que ello refleje una diferencia real de desempeño del modelo.

3.2 Métricas seleccionadas y criterios de interpretación

Métrica	Fórmula	Criterio de interpretación en este caso
Accuracy	$(VP + VN) / \text{Total}$	Proporción global de aciertos; puede ser engañosa por sí sola dado el desbalance de clases
Precision (clase 1)	$VP / (VP + FP)$	Proporción de pasajeros predichos como sobrevivientes que efectivamente lo fueron
Recall (clase 1)	$VP / (VP + FN)$	Proporción de sobrevivientes reales detectados por el modelo
F1-score (clase 1)	$2 \cdot (\text{Precision} \cdot \text{Recall}) / (\text{Precision} + \text{Recall})$	Equilibrio entre precision y recall en una sola cifra

3.3 Relación entre métricas y problema de clasificación

En el contexto del Titanic, un falso negativo (sobreviviente real clasificado como no sobreviviente) y un falso positivo (no sobreviviente clasificado como sobreviviente) tienen lecturas distintas: el recall resume la capacidad del modelo para no pasar por alto sobrevivientes reales, mientras que la precision resume qué tan confiables son las predicciones positivas del modelo. Por ello, la comparación entre arquitecturas considera las cuatro métricas de forma conjunta y no una sola de ellas.

IV. Notebook F4_Evaluacion.ipynb

El notebook F4_Evaluacion.ipynb constituye la evidencia técnica de la fase y corresponde al archivo notebooks/F4_Evaluacion.ipynb del repositorio del proyecto. Fue ejecutado en su totalidad (Restart Kernel and Run All) sin errores antes de generar las cifras, tablas y figuras de este informe.

4.1 Desarrollo del código fuente en Python

El notebook define un ColumnTransformer que integra la imputación de age (mediana) y embarked (moda), la codificación one-hot de sex y embarked, y el escalamiento estándar de las variables numéricas, seguido del MLPClassifier dentro de un mismo Pipeline. Una función común de evaluación (evaluar_pipeline) ajusta el pipeline y calcula accuracy, precision, recall, F1-score y matriz de confusión, y se reutiliza tanto para las tres evaluaciones Hold-Out como para cada fold de la validación cruzada, evitando código duplicado.

4.2 Orden lógico del flujo de evaluación

Etapas del notebook	Acción principal	Sección del informe
Carga de datos	<code>sns.load_dataset('titanic')</code>	II
Descripción y distribución de clases	Eliminación de columnas redundantes, conteo de clases	II
Partición entrenamiento/prueba	<code>train_test_split</code> estratificado 80/20	III
Pipeline de preprocesamiento	ColumnTransformer + Pipeline + función común de evaluación	III, IV

Etapas del notebook	Acción principal	Sección del informe
Evaluación Hold-Out	Ajuste y evaluación de las tres arquitecturas MLP	V, VI
Validación cruzada	StratifiedKFold (k=5) sobre el MLP de una capa oculta	VII
Interpretación	Comparación Hold-Out vs. K-Fold, fortalezas y limitaciones	VIII

4.3 Comentarios, celdas narrativas y correspondencia con el informe

El notebook incluye celdas narrativas antes y después de cada bloque de código, documentando el propósito de cada paso y la interpretación de sus resultados. Las tablas, figuras y cifras que se citan en las secciones V a VIII de este informe son las mismas que produce el notebook en su ejecución más reciente, manteniendo coherencia entre ambos documentos.

4.4 Relación con el repositorio

El notebook se aloja en la carpeta notebooks/ del repositorio del proyecto (https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2), y genera automáticamente sus figuras en la carpeta figures/fase4_evaluacion/ al ejecutarse (compatible con ejecución desde la raíz del repositorio o desde la carpeta notebooks/), evitando dependencias externas para la evidencia visual.

V. Evaluación de modelos supervisados

Se evalúan las tres arquitecturas MLP autorizadas para esta fase sobre el mismo conjunto de prueba (179 observaciones), mediante el pipeline descrito en la Sección III-IV.

5.1 Identificación de los modelos evaluados

MLP de una capa oculta (100,), MLP de dos capas ocultas (100, 50) y MLP de tres capas ocultas (100, 50, 25), todas con activación ReLU, solver Adam, max_iter=500 y random_state=42.

5.2 Reporte tabulado de resultados por modelo

Modelo	Accuracy	Precision	Recall	F1-score
MLP 1 capa oculta	0,7821	0,7679	0,6232	0,6880
MLP 2 capas ocultas	0,8156	0,7903	0,7101	0,7481
MLP 3 capas ocultas	0,8045	0,7931	0,6667	0,7244




Figura 2. Comparación Hold-Out de las tres arquitecturas MLP.

5.3 Interpretación inicial del desempeño

En esta partición de prueba, el MLP de dos capas ocultas presenta el mejor desempeño conjunto, al obtener el mayor accuracy, recall y F1-score de las tres arquitecturas. El MLP de tres capas ocultas alcanza una precision levemente superior a la de dos capas, pero con un recall inferior, asociado a una mayor cantidad de falsos negativos, mientras que el MLP de una capa oculta presenta el desempeño más bajo del conjunto en accuracy, recall y F1-score. Estas diferencias son moderadas y corresponden a una sola partición de prueba, por lo que se interpretan como una evaluación preliminar.

VI. Matriz de confusión y métricas de clasificación

La matriz de confusión permite descomponer los aciertos y errores de cada modelo en verdaderos negativos (TN), falsos positivos (FP), falsos negativos (FN) y verdaderos positivos (TP), respecto de la clase objetivo sobrevivió (1).

Modelo	TN	FP	FN	TP	Accuracy	Precision	Recall	F1-score
MLP 1 capa oculta	97	13	26	43	0,7821	0,7679	0,6232	0,6880
MLP 2 capas ocultas	97	13	20	49	0,8156	0,7903	0,7101	0,7481
MLP 3 capas ocultas	98	12	23	46	0,8045	0,7931	0,6667	0,7244




Figura 3. Matrices de confusión de las tres arquitecturas MLP (Hold-Out).

6.1 Interpretación breve de cada métrica

Accuracy: en las tres arquitecturas se ubica entre 0,78 y 0,82, lo que indica un nivel de acierto global razonable dado el desbalance moderado del dataset. Precision: entre 0,77 y 0,79; los falsos positivos (12-13 casos) se mantienen bajos y similares entre modelos, y es el MLP de tres capas quien registra la mayor precisión del conjunto (0,7931). Recall: varía más entre arquitecturas (0,62-0,71); el MLP de una capa presenta el mayor número de falsos negativos (26), es decir, la mayor cantidad de sobrevivientes reales no detectados. F1-score: refleja el mismo orden observado en recall, con el MLP de dos capas a la cabeza.

VII. Validación cruzada de la red neuronal con una capa oculta

Conforme a la pauta, la validación cruzada se aplica exclusivamente al MLP de una capa oculta, sobre el conjunto de entrenamiento (712 observaciones).

7.1 Técnica de validación utilizada

Se utiliza K-Fold estratificado (StratifiedKFold de scikit-learn) con 5 particiones, shuffle=True y random_state=42 (scikit-learn Developers, s.f.-b). Esto corresponde a una aplicación estratificada de K-Fold, que mantiene aproximadamente la misma proporción de clases de survived en cada partición, lo cual es relevante dado el desbalance moderado del dataset. El pipeline completo (imputación, codificación, escalamiento y MLP) se ajusta dentro de cada fold, usando solo los datos de entrenamiento de ese fold, sin preprocesar antes de generar las particiones.

Figura 4. Esquema K-Fold estratificado (k=5) — naranja: partición de validación




Figura 4. Esquema conceptual de K-Fold estratificado (k=5).

7.2 Resultados obtenidos por partición

Fold	Accuracy	Precision	Recall	F1-score	Iteraciones	ConvergenceWarning
1	0,8601	0,8571	0,7636	0,8077	500	Sí
2	0,7972	0,7826	0,6545	0,7129	500	Sí
3	0,8592	0,9070	0,7091	0,7959	500	Sí
4	0,8099	0,7368	0,7778	0,7568	500	Sí
5	0,8028	0,8095	0,6296	0,7083	500	Sí




Figura 5. Accuracy por fold — MLP de una capa oculta (K-Fold estratificado, k=5).

7.3 Métricas promedio y variabilidad observada

Estadístico	Accuracy	Precision	Recall	F1-score
Promedio	0,8258	0,8186	0,7069	0,7563
Desviación estándar	0,0312	0,0659	0,0651	0,0458

Matriz de confusión agregada de las cinco particiones de validación (712 observaciones en total): TN = 395, FP = 44, FN = 80, TP = 193.

Indicador	Valor
Falsos negativos (FN) agregados	80
Positivos reales (sobrevivió = 1) agregados	273
Proporción de positivos reales no detectados	29,30 %

La matriz agregada muestra qué proporción de sobrevivientes reales no fue detectada en las cinco particiones. Este resultado complementa el recall promedio y permite dimensionar los falsos negativos del modelo.

7.4 Interpretación de la estabilidad

La desviación estándar del accuracy (0,0312) es reducida respecto de su promedio, lo que indica que el desempeño global del MLP de una capa oculta se mantiene relativamente estable entre particiones. La variabilidad es mayor en precision (0,0659) y recall (0,0651), lo cual es esperable dado el tamaño moderado de cada fold de validación (entre 142 y 143 observaciones) y el desbalance de clases: con menos observaciones de la clase positiva por fold, unos pocos casos mal clasificados modifican proporcionalmente más estas métricas que el accuracy. En los cinco folds se registró ConvergenceWarning al alcanzar max_iter=500, por lo que estos resultados de K-Fold deben considerarse preliminares: el optimizador no completó su convergencia natural en ninguna de las cinco

particiones, lo que limita la interpretación de la estabilidad estimada, y no se corrige mediante un ajuste adicional de hiperparámetros, conforme al alcance de esta fase.

7.5 Relación entre tamaño del dataset, costo computacional y estabilidad esperada

El conjunto de entrenamiento (712 observaciones) es de tamaño moderado, lo que hace viable aplicar K-Fold con cinco particiones sin un costo computacional excesivo: cada fold entrena una red MLP relativamente pequeña sobre entre 569 y 570 observaciones. Un número mayor de particiones (por ejemplo, diez) aumentaría el costo computacional de forma proporcional y reduciría el tamaño de cada fold de validación, lo que podría aumentar la variabilidad de precision y recall sin una ganancia clara en la estimación del accuracy.

VIII. Interpretación comparativa de resultados

Hold-Out (Sección V-VI) y K-Fold (Sección VII) son protocolos distintos: el Hold-Out evalúa una única partición fija de prueba, mientras que el K-Fold promedia el desempeño en cinco particiones internas del conjunto de entrenamiento. Por esta razón se presentan por separado, y el promedio del K-Fold no se incorpora como una cuarta arquitectura dentro del ranking Hold-Out.

8.1 Comparación preliminar del desempeño entre modelos

Entre las tres arquitecturas evaluadas mediante Hold-Out, el MLP de dos capas ocultas presenta el mejor desempeño conjunto, al obtener el mayor accuracy, recall y F1-score. El MLP de tres capas alcanza una precision levemente superior, pero presenta un recall menor, asociado a una mayor cantidad de falsos negativos. Por tanto, el MLP de dos capas constituye el candidato preliminar con mejor equilibrio de métricas en esta partición, sin que ello represente una selección definitiva. El MLP de una capa oculta obtiene el desempeño más bajo en Hold-Out, aunque es la única arquitectura evaluada también mediante K-Fold, cuyo accuracy promedio (0,8258) difiere de su accuracy puntual en Hold-Out (0,7821). Esta diferencia no debe leerse como que K-Fold produce naturalmente un mejor desempeño: son protocolos distintos, aplicados sobre particiones distintas, por lo que el promedio K-Fold no representa una mejora del modelo respecto del resultado Hold-Out. La diferencia observada puede estar asociada a la composición particular de las muestras de validación de cada protocolo, y por ello ambos resultados se reportan por separado y no se incorporan en un mismo ranking.

8.2 Interpretación de la estabilidad del modelo validado

El MLP de una capa oculta muestra una variabilidad baja en accuracy (desviación estándar de 0,0312) y una variabilidad moderada en precision y recall entre folds, lo que sugiere un desempeño razonablemente estable pero sensible a la composición específica de cada partición en la detección de sobrevivientes. Las cinco particiones registraron ConvergenceWarning al alcanzar max_iter=500, por lo que esta estimación de estabilidad debe considerarse preliminar.

8.3 Fortalezas y limitaciones

Arquitectura	Fortaleza	Limitación
MLP 1 capa (100,)	Arquitectura más simple; única evaluada también mediante K-Fold, lo que permite estimar su estabilidad	Menor accuracy, recall y F1-score que las otras dos arquitecturas en Hold-Out; ConvergenceWarning en todas sus ejecuciones

Arquitectura	Fortaleza	Limitación
MLP 2 capas (100, 50)	Mejor equilibrio entre precision y recall; mayor accuracy, recall y F1-score en Hold-Out	Mayor complejidad que la red de una capa; también presenta ConvergenceWarning
MLP 3 capas (100, 50, 25)	Mayor precision en Hold-Out; converge antes de max_iter=500 (sin ConvergenceWarning)	Recall inferior al de dos capas (más falsos negativos); mayor complejidad y menor interpretabilidad

8.4 Implicancias para la selección preliminar del modelo

Si se considerara únicamente el accuracy puntual en Hold-Out, el MLP de dos capas ocultas aparecería como preferible. Sin embargo, la pauta exige considerar las cuatro métricas, los errores, la estabilidad y la complejidad en conjunto: el MLP de dos capas ofrece el mejor balance entre accuracy, recall y F1-score en esta partición; el de tres capas prioriza precision sobre recall y converge sin advertencias; y el de una capa, pese a su desempeño puntual más bajo, es el único con evidencia de estabilidad mediante validación cruzada, aunque limitada por la presencia de ConvergenceWarning en los cinco folds. Con la evidencia disponible en esta fase, ninguna arquitectura domina de forma inequívoca en las cuatro métricas simultáneamente, por lo que la selección del modelo final debe postergarse hasta contar con evidencia adicional, y no corresponde declarar aquí un ganador definitivo.

IX. Justificación metodológica de la evaluación utilizada

9.1 Pertinencia de las métricas utilizadas

Accuracy, precision, recall y F1-score son pertinentes porque el problema es de clasificación binaria con clases moderadamente desbalanceadas (61,6 % / 38,4 %). El accuracy por sí solo puede ocultar un desempeño deficiente sobre la clase minoritaria; precision y recall, calculados sobre sobrevivió (1), exponen ese comportamiento de forma directa, y el F1-score resume el equilibrio entre ambas cuando ninguna debe priorizarse de forma absoluta (scikit-learn Developers, s.f.-c).

9.2 Justificación de la validación cruzada aplicada

Se aplica K-Fold estratificado con cinco particiones al MLP de una capa oculta porque el conjunto de entrenamiento (712 observaciones) es lo suficientemente grande para dividirlo en cinco folds sin dejar particiones demasiado pequeñas, y porque la estratificación conserva la proporción de clases en cada fold, evitando que una partición particular concentre desproporcionadamente la clase minoritaria (scikit-learn Developers, s.f.-b; Géron, 2019).

9.3 Comparación entre Hold-Out, K-Fold y Leave-One-Out

Técnica	Costo computacional	Estabilidad esperada	Pertinencia en este caso
Hold-Out	Bajo: un solo entrenamiento y una sola evaluación	Menor; depende de una única partición de prueba	Usado para comparar las tres arquitecturas sobre el mismo conjunto de prueba
K-Fold (k=5)	Moderado: cinco entrenamientos y cinco evaluaciones	Mayor que Hold-Out; promedia el desempeño en varias particiones	Usado exclusivamente para el MLP de una capa oculta, exigido por la pauta

Técnica	Costo computacional	Estabilidad esperada	Pertinencia en este caso
Leave-One-Out	Alto: aproximadamente 712 entrenamientos, uno por observación	Baja varianza teórica, pero de costo elevado para este tamaño de dataset	No aplicado en esta fase por su costo computacional frente al tamaño del dataset

9.4 Razón para utilizar cinco folds

La elección de K-Fold con cinco particiones responde al tamaño moderado del conjunto de entrenamiento, compuesto por 712 observaciones. El Hold-Out presenta un costo computacional menor, pero su estimación depende de una sola partición. K-Fold requiere entrenar la red cinco veces y permite calcular el desempeño promedio y su variabilidad. Leave-One-Out requeriría aproximadamente 712 entrenamientos sobre este conjunto, lo que supone un costo considerablemente mayor para una red neuronal sin una ventaja proporcional para el objetivo de este avance. Por ello, cinco folds ofrecen un compromiso razonable entre costo computacional y estabilidad esperada de las métricas.

9.5 Coherencia con el problema de clasificación

El protocolo aplicado evalúa las tres arquitecturas sobre datos no vistos (conjunto de prueba) y añade una validación interna adicional (K-Fold) para la arquitectura de una capa oculta, lo que es coherente con un problema de clasificación binaria donde interesa tanto el desempeño puntual como la estabilidad del modelo ante distintas particiones de los datos de entrenamiento.

X. Conclusiones

El avance de la Fase 4 permitió evaluar el desempeño de las tres arquitecturas MLP desarrolladas en la Fase 3 del proyecto sobre el mismo conjunto de prueba del dataset Titanic, y aplicar validación cruzada K-Fold estratificada a la red de una capa oculta, corrigiendo un problema de fuga de información presente en una versión previa del análisis mediante el uso de Pipeline y ColumnTransformer.

Entre las tres arquitecturas evaluadas mediante Hold-Out, el MLP de dos capas ocultas es el candidato preliminar con mejor equilibrio de métricas, al obtener el mayor accuracy (0,8156), recall (0,7101) y F1-score (0,7481). El MLP de tres capas ocultas presenta la mayor precisión (0,7931), aunque con un recall menor (0,6667) asociado a más falsos negativos; y el MLP de una capa oculta obtuvo el desempeño más bajo del conjunto (accuracy 0,7821).

El MLP de una capa oculta es el modelo validado mediante K-Fold estratificado ($k=5$) por exigencia de la pauta. Su validación cruzada mostró un accuracy promedio de 0,8258 con desviación estándar de 0,0312, y una variabilidad algo mayor en precision (0,0659) y recall (0,0651), lo que sugiere un desempeño razonablemente estable, aunque más sensible a la composición de cada fold en la detección de sobrevivientes. Las advertencias de convergencia (ConvergenceWarning) registradas en el MLP de una y dos capas, y en los cinco folds de la validación cruzada, limitan la interpretación de estos resultados: el optimizador no completó su convergencia natural bajo `max_iter=500`, por lo que las cifras de K-Fold se consideran preliminares.

Estas conclusiones son preliminares: se basan en una sola partición Hold-Out y en la validación cruzada de una única arquitectura, por lo que no constituyen una selección definitiva del modelo final. La elección entre las tres arquitecturas para etapas posteriores del proyecto deberá considerar conjuntamente las

cuatro métricas, la estabilidad observada y la complejidad de cada red, y no basarse únicamente en el accuracy ni en una sola partición Hold-Out.

Como implicancia para el informe final de la Fase 4, se recomienda mantener el mismo protocolo de evaluación (Pipeline sin fuga de información, partición estratificada y K-Fold estratificado) al incorporar evidencia adicional, documentando de igual forma cualquier advertencia de convergencia que se presente.

XI. Uso de fuentes, citación y referencias

El informe integra fuentes del material docente, documentación técnica oficial de scikit-learn y una fuente académica complementaria para sustentar las decisiones conceptuales, metodológicas y técnicas del análisis. Las citas en el texto (por ejemplo, en las Secciones II, III, VII y IX) corresponden una a una con el listado de referencias siguiente, en formato APA 7.^a edición.

Material docente

Ruete Zúñiga, D. (2026a). Métricas de evaluación: accuracy, F1-score, matriz de confusión [Apunte]. Universidad Andrés Bello.

Ruete Zúñiga, D. (2026b). Técnicas de evaluación: validación cruzada (K-Fold Cross-Validation, Leave-One-Out, Hold-Out) [Apunte]. Universidad Andrés Bello.

Documentación técnica oficial

scikit-learn Developers. (s. f.-a). sklearn.pipeline.Pipeline. Scikit-learn documentation. Recuperado el 27 de agosto de 2026, de <https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html>

scikit-learn Developers. (s. f.-b). sklearn.model_selection.StratifiedKFold. Scikit-learn documentation. Recuperado el 27 de agosto de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html

scikit-learn Developers. (s. f.-c). Metrics and scoring: quantifying the quality of predictions. Scikit-learn documentation. Recuperado el 27 de agosto de 2026, de https://scikit-learn.org/stable/modules/model_evaluation.html

Fuente académica complementaria

Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow (2.^a ed.). O'Reilly Media.

XII. Anexos

Anexo A. Tabla consolidada de resultados Hold-Out

Modelo	TN	FP	FN	TP	Accuracy	Precision	Recall	F1-score
MLP 1 capa oculta	97	13	26	43	0,7821	0,7679	0,6232	0,6880
MLP 2 capas ocultas	97	13	20	49	0,8156	0,7903	0,7101	0,7481
MLP 3 capas ocultas	98	12	23	46	0,8045	0,7931	0,6667	0,7244

Anexo B. Tabla consolidada de resultados por fold (K-Fold, MLP 1 capa oculta)

Fold	Accuracy	Precision	Recall	F1-score	Iteraciones	ConvergenceWarning
1	0,8601	0,8571	0,7636	0,8077	500	Sí
2	0,7972	0,7826	0,6545	0,7129	500	Sí
3	0,8592	0,9070	0,7091	0,7959	500	Sí
4	0,8099	0,7368	0,7778	0,7568	500	Sí
5	0,8028	0,8095	0,6296	0,7083	500	Sí
Promedio	0,8258	0,8186	0,7069	0,7563	-	5 de 5 folds
Desv. estándar	0,0312	0,0659	0,0651	0,0458	-	-

Anexo C. Figuras utilizadas en el análisis

Figura	Origen (notebook)	Descripción
Figura 1	fig01_distribucion_clases.png	Distribución de clases de la variable objetivo survived
Figura 2	fig02_comparacion_holdout.png	Comparación Hold-Out de accuracy, precision, recall y F1-score entre las tres arquitecturas MLP
Figura 3	fig03_matrices_confusion_holdout.png	Matrices de confusión de las tres arquitecturas MLP sobre el conjunto de prueba
Figura 4	fig04_esquema_kfold.png	Esquema conceptual de la validación cruzada K-Fold estratificada (k=5)
Figura 5	fig05_accuracy_por_fold.png	Accuracy obtenido por cada uno de los 5 folds del MLP de una capa oculta

Anexo D. Resultado complementario: matriz de confusión agregada y falsos negativos de la validación cruzada

	Predicción 0	Predicción 1
Real 0	395	44
Real 1	80	193

Esta matriz agrega las predicciones de las cinco particiones de validación del K-Fold (712 observaciones en total) y complementa la lectura por fold presentada en el Anexo B y la Sección VII. Sobre esta matriz, los falsos negativos agregados (FN = 80) representan el 29,30 % de los 273 positivos reales (sobrevivió = 1) considerados en las cinco particiones.