



MCDI504

MACHINE LEARNING I

AVANCE DEL PROYECTO - FASE 1: DEFINICIÓN Y ORIENTACIÓN DE LA SITUACIÓN

Integrantes: Enzo Pinilla · Claudio Alarcón · Luis Rodrigo Espinoza

Curso: MCDI504 - Machine Learning I

Docente: David Ruete Zúñiga

Grupo: 2

Fecha: 09 de agosto de 2026

Repositorio: https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

Tabla de contenido

II. Introducción y contextualización	3
III. Definición de la problemática y objetivos del proyecto	4
3.1 Formulación del problema	4
3.2 Pregunta analítica	4
3.3 Objetivo general	4
3.4 Objetivos específicos	4
3.5 Tipo de datos y alcance	5
3.6 Relación con KDD y viabilidad	5
IV. Clasificación del tipo de aprendizaje	5
V. Relación entre Machine Learning y metodología KDD	6
VI. Notebook F1_Definición.ipynb	7
6.1 Estructura del flujo	7
6.2 Calidad y estadística descriptiva	7
6.3 Correlación de Pearson: qué sí responder y qué no	8
6.4 Separabilidad y normalización	11
VII. Comparación de enfoques	12
VIII. Documentación del proceso	12
8.1 Estructura del repositorio	13
IX. Conclusiones	13
X. Uso de fuentes, citación y referencias	14
XI. Anexos	14
Anexo A. Diccionario de variables	14
Anexo B. Matriz numérica de correlación	15
Anexo C. Matriz de p-valores	15
Anexo D. Muestra de base normalizada	15

II. Introducción y contextualización

El presente informe corresponde al avance de la Fase 1 del proyecto de MCDI504 - Machine Learning I. Esta etapa establece la definición analítica, la orientación metodológica y la evidencia técnica inicial, sin entrenar todavía modelos predictivos. El propósito es construir una relación explícita entre situación de análisis, datos disponibles, variable objetivo, tipo de aprendizaje y proceso KDD (Ruede Zúñiga, 2026a).

El caso se contextualiza en IrisFlow, un escenario ficticio de recepción y clasificación de flora ornamental. En este contexto, una clasificación manual de flores Iris puede depender de la observación de sus características morfológicas y del criterio de quien realiza la tarea. La situación de análisis consiste en determinar si cuatro medidas cuantitativas -largo y ancho del sépalo, largo y ancho del pétalo- entregan evidencia suficiente para orientar una solución de clasificación de especies basada en datos.

El dataset Iris se carga desde scikit-learn y contiene 150 observaciones, cuatro variables numéricas y una etiqueta de especie con tres categorías. La documentación oficial de scikit-learn presenta Iris como un conjunto de clasificación multiclase con 150 muestras, cuatro características reales y tres clases balanceadas (scikit-learn developers, s. f.). La existencia de una etiqueta conocida, Species, permite plantear el problema como aprendizaje supervisado de clasificación multiclase, en concordancia con la distinción entre tareas supervisadas y no supervisadas descrita en la literatura de Machine Learning (Alpaydin, 2010; Géron, 2019).

La Fase 1 se mantiene deliberadamente preparatoria. El notebook documenta carga, estructura, calidad, estadística descriptiva, visualización, correlación de Pearson entre variables continuas, p-valores, separabilidad por especie y una demostración de normalización Min-Max. Ninguno de estos pasos equivale a entrenamiento de un clasificador; su función es fundamentar decisiones y preparar una ruta reproducible para las fases siguientes.

Elemento	Aplicación al caso
Contexto	IrisFlow: escenario ficticio de recepción y clasificación de flores Iris.
Situación	La asignación manual de especie puede depender de similitudes morfológicas y criterio humano.
Datos	150 observaciones; 4 predictores numéricos continuos; Species categórica con 3 clases.
Objetivo analítico	Justificar un enfoque de clasificación supervisada y dejar evidencia técnica para F2-F4.
Relación problema-datos-objetivo	Las medidas morfológicas son las entradas; Species es la salida conocida; el resultado esperado es una clase.

III. Definición de la problemática y objetivos del proyecto

3.1 Formulación del problema

La problemática analítica consiste en transformar una necesidad de clasificación de especies en una pregunta abordable con datos. Cada observación representa una flor Iris y contiene cuatro medidas morfológicas continuas junto con la especie observada. Se requiere establecer si la estructura y calidad de esos datos permiten sostener, metodológicamente, una futura solución de clasificación automática.

3.2 Pregunta analítica

¿En qué medida las variables Sepal.Length, Sepal.Width, Petal.Length y Petal.Width permiten sustentar un enfoque de aprendizaje supervisado para clasificar una flor Iris como setosa, versicolor o virginica?

3.3 Objetivo general

Definir y justificar el enfoque metodológico inicial de Machine Learning para la clasificación multiclase de especies Iris, mediante la caracterización estructural, descriptiva y exploratoria de los datos y su articulación con las etapas de KDD.

3.4 Objetivos específicos

- Caracterizar la estructura, tipos de variables, calidad y balance del dataset Iris.
- Describir las variables predictoras mediante medidas estadísticas y visualizaciones iniciales.
- Analizar asociaciones lineales entre las cuatro variables predictoras continuas mediante correlación de Pearson y p-valores.
- Explorar la separabilidad de las especies mediante distribuciones agrupadas por Species, conservando su carácter nominal.
- Demostrar una normalización Min-Max sobre las variables de entrada como preparación reproducible, sin asumir que será obligatoria para todos los algoritmos futuros.
- Comparar el aprendizaje supervisado con alternativas no supervisadas, por refuerzo y regresión, justificando los descartes según datos, objetivo, factibilidad y utilidad.
- Relacionar las decisiones del notebook con selección, preprocesamiento, transformación, minería de datos e interpretación dentro de KDD.

3.5 Tipo de datos y alcance

Aspecto	Definición
Unidad de análisis	Una flor Iris.
Predictores	Sepal.Length, Sepal.Width, Petal.Length y Petal.Width; numéricas continuas en centímetros.
Variable objetivo	Species; categórica nominal: setosa, versicolor y virginica.
Cantidad	150 observaciones.
Balance	50 observaciones por clase.
Alcance F1	Definición, exploración, preparación y justificación metodológica. Sin entrenamiento, validación ni evaluación predictiva.

3.6 Relación con KDD y viabilidad

KDD describe un proceso iterativo que integra selección, preprocesamiento, transformación, minería de datos e interpretación para convertir datos en conocimiento útil (Fayyad et al., 1996). En esta Fase 1 se ejecutan y documentan principalmente selección y preprocesamiento, se demuestra una transformación controlada de escala y se dejan minería de datos e interpretación predictiva para fases posteriores. La viabilidad inicial es alta porque la etiqueta está disponible para todas las observaciones y la pregunta analítica coincide con una tarea de clasificación; sin embargo, la utilidad predictiva real solo podrá comprobarse mediante entrenamiento y evaluación posterior.

IV. Clasificación del tipo de aprendizaje

El enfoque seleccionado es aprendizaje supervisado de clasificación multiclase. La decisión no surge de una preferencia por un algoritmo, sino de la estructura del problema: existe una variable objetivo conocida y categórica, y se busca asignar una observación a una de tres clases. En aprendizaje supervisado, los ejemplos etiquetados permiten aprender una relación entre entradas y salida; cuando la salida es categórica, el subproblema corresponde a clasificación (Alpaydin, 2010; Géron, 2019).

Criterio	Evidencia del proyecto	Consecuencia metodológica
Variable objetivo	Species está disponible para las 150 observaciones.	Aprendizaje supervisado.
Tipo de objetivo	Species es nominal con tres categorías.	Clasificación multiclase.
Predictores	Cuatro medidas numéricas continuas.	Entradas compatibles con clasificadores estándar.

Criterio	Evidencia del proyecto	Consecuencia metodológica
Propósito	Asignar una especie a partir de medidas observadas.	Predicción de clase, no estimación continua.
Señal secuencial	No existe agente, acciones ni recompensa.	Descarta aprendizaje por refuerzo como enfoque principal.

Los tres tipos generales de aprendizaje se distinguen por la señal disponible. El supervisado utiliza etiquetas; el no supervisado busca estructura sin etiquetas; el aprendizaje por refuerzo aprende mediante interacción y recompensas. En Iris, la etiqueta Species ya es conocida, por lo que la clasificación supervisada utiliza directamente la información que responde a la pregunta del proyecto (Provost & Fawcett, 2013).

V. Relación entre Machine Learning y metodología KDD

Machine Learning no reemplaza a KDD. KDD organiza el flujo completo de descubrimiento de conocimiento, mientras que el modelamiento de Machine Learning aparece principalmente en la etapa de minería de datos. La rúbrica solicita explicar la función concreta de cada etapa; por ello, el proyecto se vincula etapa por etapa y no solo de manera conceptual (Ruede Zúñiga, 2026a; Fayyad et al., 1996).



Fase 1: definición, evidencia exploratoria y preparación; sin entrenamiento de modelos

Figura 1. Flujo KDD aplicado al proyecto IrisFlow. Elaboración propia a partir de Fayyad et al. (1996) y material docente.

Etapas KDD	Función en el proyecto	Evidencia técnica
Selección	Identificar el dataset, las cuatro variables morfológicas y Species como elementos pertinentes.	load_iris(), creación de bbdd1, definición de X e y.
Preprocesamiento	Revisar forma, tipos, nulos, duplicados, balance y distribuciones.	shape, dtypes, isnan(), duplicated(), describe(), boxplot.
Transformación	Preparar variables sin perder su significado semántico.	Pearson solo entre continuas; Min-Max solo en X; Species permanece categórica.
Minería de datos / ML	Aplicar algoritmos de clasificación supervisada.	No ejecutado en F1; se proyecta a F2-F4.
Interpretación	Evaluar utilidad y desempeño del conocimiento/modelo.	En F1 se interpretan señales exploratorias; métricas predictivas quedan para fases siguientes.

Esta separación es importante: la correlación de Pearson y los boxplots corresponden a evidencia exploratoria, mientras que la normalización Min-Max sí constituye una transformación de preparación. Ninguno de estos pasos es un modelo entrenado. Mantener ese límite evita adelantar fases que la evaluación no solicita.

VI. Notebook F1_Definición.ipynb

El archivo final se denomina notebooks/F1_Definicion.ipynb, se entrega ejecutado y sin errores y guarda las figuras directamente en ../figures/, sin requerir una carpeta outputs/.

6.1 Estructura del flujo

Bloque	Propósito	Salida/evidencia
0. Reproducibilidad	Mantener instalación local y Colab documentada.	requirements.txt + instrucciones de ejecución local/Colab.
1. Problema y objetivos	Formalizar pregunta, alcance y viabilidad.	Narrativa coherente con el informe.
2-3. Datos y calidad	Cargar Iris y verificar estructura.	150x5, tipos, nulos, duplicados, balance.
4-5. Enfoque y KDD	Justificar clasificación y mapear proceso.	Tabla de decisión + diagrama KDD.
6. Pearson	Analizar asociación lineal entre predictores.	Matriz de correlación y p-valores.
7. Separabilidad	Relacionar predictores con Species sin ordinalizarla.	Boxplots por especie.
8. Normalización	Demostrar preparación Min-Max solo en X.	Salida visible de <code>bbdd_norm.head()</code> ; Species permanece categórica.
9-11. Comparación/trazabilidad/cierre	Justificar descartes y decisiones.	Tablas y conclusiones reproducibles.

6.2 Calidad y estadística descriptiva

La ejecución confirma 150 filas y 5 columnas, sin valores faltantes y con 50 observaciones por especie. Se detecta un registro duplicado exacto. El duplicado queda documentado y no se elimina en F1, porque no existe un identificador que permita decidir si es un error de captura o dos observaciones legítimas con las mismas medidas. Antes de un futuro split de entrenamiento/prueba, esta decisión deberá resolverse para evitar que copias idénticas contaminen la evaluación.




Figura 2. Boxplot de las cuatro variables predictorias. Evidencia generada por `F1_Definicion.ipynb`.

6.3 Correlación de Pearson:

La correlación de Pearson mide la fuerza y dirección de una asociación lineal entre dos variables numéricas; SciPy implementa `pearsonr` y entrega tanto el coeficiente como un p-valor para contrastar correlación cero (SciPy community, s. f.). Por este motivo, el análisis principal se realiza únicamente sobre `Sepal.Length`, `Sepal.Width`, `Petal.Length` y `Petal.Width`.

Esta decisión corrige una ambigüedad frecuente del código didáctico: técnicamente es posible codificar `Species` como 1, 2 y 3 y calcular una matriz numérica, pero esos códigos representan nombres de categorías, no distancias ni un orden natural.

Por tanto, una correlación Pearson con `Species` codificada no se usa aquí como evidencia inferencial de relación con la especie. Para responder si las medidas diferencian clases se utilizan distribuciones agrupadas por `Species`.




Figura 3. Correlación de Pearson entre las cuatro variables predictoras continuas.

El resultado más alto corresponde a Petal.Length-Petal.Width ($r \approx 0,963$). También se observan asociaciones altas entre Sepal.Length y Petal.Length ($r \approx 0,872$) y entre Sepal.Length y Petal.Width ($r \approx 0,818$). Sepal.Length-Sepal.Width presenta una asociación débil ($r \approx -0,118$).




Figura 4. P-valores de Pearson entre variables predictoras continuas.

Cinco de los seis pares distintos presentan $p < 0,05$. La excepción es Sepal.Length-Sepal.Width, con $p \approx 0,152$. Un p-valor pequeño apoya evidencia contra correlación cero bajo los supuestos del contraste, pero no implica causalidad ni garantiza utilidad predictiva; la fuerza se interpreta con r y el desempeño futuro deberá evaluarse con modelos y métricas.

6.4 Separabilidad y normalización

Distribución de variables predictoras por especie




Figura 5. Distribución de predictores agrupada por Species. Las variables del pétalo muestran la separación visual más clara.

La distribución por especie muestra diferencias especialmente marcadas en Petal.Length y Petal.Width, mientras Sepal.Width presenta mayor solapamiento. Esto constituye evidencia exploratoria de separabilidad potencial, sin demostrar todavía precisión de clasificación.

El material docente incluye MinMaxScaler como preparación inicial (Ruete Zúñiga, 2026b). El notebook reproduce esta transformación únicamente sobre las cuatro variables de entrada y luego conserva Species en su forma categórica.

El escalamiento deja una versión preparada para algoritmos sensibles a magnitud, pero su uso final deberá decidirse según el clasificador escogido en F2; no todos los modelos lo requieren de la misma forma.

VII. Comparación de enfoques

La comparación se realiza considerando datos disponibles, variable objetivo, finalidad, factibilidad técnica y utilidad del resultado, tal como solicita la orientación del profesor (Ruede Zúñiga, 2026a).

Enfoque	Requisito / señal	Aplicación posible	Decisión y justificación
Supervisado - clasificación	X + etiqueta categórica conocida	Predecir setosa, versicolor o virginica.	Seleccionado: coincide exactamente con Species y con el objetivo de asignar una clase.
No supervisado - clustering	Predictores sin necesidad de etiqueta	Explorar grupos por similitud.	Complementario, no principal: ignoraría una etiqueta ya disponible y no garantiza que clusters correspondan a las especies reales.
Aprendizaje por refuerzo	Estado, acciones, interacción y recompensa	Optimizar decisiones secuenciales.	Descartado: la clasificación de cada flor es independiente; no existe entorno secuencial ni señal de recompensa.
Supervisado - regresión	Objetivo numérico continuo	Estimar una medida morfológica.	Descartado para la pregunta central: Species es categórica; regresión respondería otra pregunta.

Por tanto, la clasificación supervisada no solo es conceptualmente compatible: es la alternativa que utiliza la información disponible con mayor correspondencia con la pregunta analítica. El clustering puede conservarse como análisis exploratorio adicional en otra fase, pero no sustituye el objetivo predictivo actual.

VIII. Documentación del proceso

La trazabilidad permite reconstruir qué decisión se tomó, por qué se tomó y dónde quedó evidenciada.

Decisión / cambio	Justificación	Evidencia
Usar contexto IrisFlow como escenario ficticio	Transforma el dataset pedagógico en una situación analítica con propósito.	Informe II-III; notebook sección 1.
Mantener Species categórica	Es nominal y no posee orden natural.	bbdd1, y, análisis por grupos.
Pearson solo entre predictores	Evita interpretar códigos de categoría como magnitudes.	Sección 6 del notebook; matriz mostrada + Figuras 3 y 4.
Incorporar p-valores	Complementa la magnitud de r con evidencia estadística.	calculate_pvalues() y Figura 4.
Documentar duplicado sin eliminarlo	No hay identificador/contexto suficiente para decidir si es error.	Sección 3 del notebook; salida de duplicated().
Incluir Min-Max como demostración	Alinea el flujo con el apunte docente y deja preparación reproducible.	Sección 8 del notebook; salida visible de bbdd_norm.head().

Decisión / cambio	Justificación	Evidencia
No entrenar modelos	La Fase 1 evalúa definición y orientación, no modelamiento.	Ausencia de fit() de clasificadores; conclusiones.

8.1 Estructura del repositorio

```

MCDI504_MACHINE_LEARNING_1_GRUPO_2/
├── docs/
│   └── MCDI504_S1_1_GRUPO2.pdf
├── figures/
│   ├── 01_flujo_kdd.png
│   ├── 02_boxplot_general.png
│   ├── 03_correlacion_pearson.png
│   ├── 04_pvalores_pearson.png
│   └── 05_boxplots_por_especie.png
├── notebooks/
│   └── F1_Definicion.ipynb
├── .gitignore
├── README.md
└── requirements.txt

```

El informe argumenta; el notebook ejecuta; figures/ conserva la evidencia visual y el README explica la reproducción.

El repositorio real del grupo es

https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

Antes de la entrega definitiva se verifico con una ejecución completa mediante Restart & Run All.

IX. Conclusiones

La Fase 1 permite convertir una situación de clasificación de flores en un problema de ciencia de datos formal y trazable. La variable Species está disponible para las 150 observaciones y representa tres clases nominales; junto con cuatro predictores continuos, esta estructura justifica el aprendizaje supervisado de clasificación multiclase. La selección metodológica se fundamenta, por tanto, en la relación entre problema, datos y salida esperada, y no en la elección anticipada de un algoritmo.

La exploración confirma datos completos y clases balanceadas, y documenta un duplicado exacto cuya naturaleza no puede determinarse sin información adicional. Las variables del pétalo presentan asociaciones lineales fuertes entre sí y muestran diferencias visuales importantes entre especies. Estas evidencias respaldan la factibilidad de continuar con clasificación, pero se interpretan como señales exploratorias: no demuestran todavía rendimiento predictivo.

La decisión de aplicar Pearson solo entre variables continuas y conservar Species como categórica evita convertir una etiqueta nominal en una escala artificial. Para relacionar medidas con la especie se utilizan comparaciones por grupo. En paralelo, la normalización Min-Max se incluye como transformación preparatoria coherente con el material docente, pero su uso definitivo se reserva para la fase en que se seleccionen algoritmos concretos.

Dentro de KDD, la Fase 1 cubre selección, preprocesamiento y preparación/transformación, dejando minería de datos e interpretación predictiva para F2-F4. La continuidad propuesta es entrenar y

comparar clasificadores, definir una estrategia de partición y validación, y evaluar el desempeño con métricas adecuadas. El repositorio conserva la correspondencia entre informe, notebook, figuras y celdas ejecutadas, permitiendo reproducir y auditar las decisiones tomadas.

X. Uso de fuentes, citación y referencias

Las decisiones conceptuales y técnicas se sustentan en material docente, documentación oficial y literatura académica. Las citas se integran en los apartados donde se emplean, y el listado siguiente conserva correspondencia con las fuentes citadas.

- Alpaydin, E. (2010). Introduction to machine learning (2nd ed.). MIT Press.
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37-54.
- Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow (2nd ed.). O'Reilly Media.
- Provost, F., & Fawcett, T. (2013). Data science for business. O'Reilly Media.
- Ruete Zúñiga, D. (2026a). Presentación Tarea Fase 1 MCDI504 [Presentación de clase]. Universidad Andrés Bello.
- Ruete Zúñiga, D. (2026b). Fase 1: Estadística descriptiva, correlación y normalización de datos [Apunte y código de clase]. Universidad Andrés Bello.
- pandas development team. (s. f.). pandas documentation. <https://pandas.pydata.org/docs/>
- scikit-learn developers. (s. f.). The Iris dataset / load_iris. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_iris.html
- SciPy community. (s. f.). scipy.stats.pearsonr. SciPy
- documentation. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.pearsonr.html>

XI. Anexos

Anexo A. Diccionario de variables

Variable	Tipo	Descripción	Uso
Sepal.Length	Númerica continua	Longitud del sépalo (cm).	Predictor.
Sepal.Width	Númerica continua	Ancho del sépalo (cm).	Predictor.
Petal.Length	Númerica continua	Longitud del pétalo (cm).	Predictor.
Petal.Width	Númerica continua	Ancho del pétalo (cm).	Predictor.
Species	Categorica nominal	setosa, versicolor o virginica.	Variable objetivo.

Anexo B. Matriz numérica de correlación

Variable	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.000	-0.118	0.872	0.818
Sepal.Width	-0.118	1.000	-0.428	-0.366
Petal.Length	0.872	-0.428	1.000	0.963
Petal.Width	0.818	-0.366	0.963	1.000

Anexo C. Matriz de p-valores

Variable	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	0	1.519e-01	1.039e-47	2.325e-37
Sepal.Width	1.519e-01	0	4.513e-08	4.073e-06
Petal.Length	1.039e-47	4.513e-08	0	4.675e-86
Petal.Width	2.325e-37	4.073e-06	4.675e-86	0

Anexo D. Muestra de base normalizada

Fila	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	0.2222	0.6250	0.0678	0.0417	setosa
1	0.1667	0.4167	0.0678	0.0417	setosa
2	0.1111	0.5000	0.0508	0.0417	setosa
3	0.0833	0.4583	0.0847	0.0417	setosa
4	0.1944	0.6667	0.0678	0.0417	setosa