

MCDI504

MACHINE LEARNING I

AVANCE DEL PROYECTO — FASE 2: IMPLEMENTACIÓN DE MODELOS DE REGRESIÓN SUPERVISADA

Integrantes: Enzo Pinilla · Claudio Alarcón · Luis Rodrigo Espinoza

Curso: MCDI504 - Machine Learning I

Docente: David Ruete Zúñiga

Grupo: 2

Evaluación: Avance del proyecto, Fase 2 — Semana 2, Evaluación Formativa 2

Fecha: 16-08-2026

Repositorio: https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

Tabla de contenido

I. Portada e índice.....	1
II. Introducción y contextualización.....	3
III. Objetivos.....	3
IV. Descripción del conjunto de datos y preprocesamiento	4
V. Análisis exploratorio orientado al modelamiento.....	5
VI. Modelo de regresión lineal simple	8
VII. Modelo de árboles de decisión para regresión.....	9
VIII. Modelo de redes neuronales para regresión.....	11
IX. Análisis complementario	12
X. Evaluación y comparación de modelos	12
XI. Selección del modelo	13
XII. Diagnóstico y limitaciones	14
XIII. Notebook y trazabilidad	15
XIV. Repositorio.....	15
XV. Conclusiones	15
XVI. Uso de fuentes, citación y referencias	16
XVII. Anexos	17

II. Introducción y contextualización

El presente informe corresponde al Avance del Proyecto — Fase 2: Implementación de Modelos de Regresión Supervisada, del curso MCDI504 – Machine Learning I. Esta etapa avanza desde la definición analítica desarrollada en la Fase 1 hacia la construcción efectiva de un pipeline predictivo: preparación de los datos, entrenamiento de modelos de regresión y evaluación de su desempeño mediante métricas estadísticas.

El problema corresponde a regresión supervisada porque la variable objetivo que se busca predecir, MedHouseVal, es numérica continua. El conjunto de datos utilizado es California Housing, disponible mediante scikit-learn, que reúne información socioeconómica y geográfica de distritos censales de California (censo de 1990). El objetivo analítico es estimar el valor mediano de vivienda de un distrito a partir de ocho variables predictoras — ingreso, antigüedad del parque habitacional, tamaño de las viviendas, población, ocupación y ubicación geográfica — y comparar distintos enfoques de modelamiento sobre datos de prueba no utilizados en el entrenamiento.

A diferencia de la Fase 1, que se mantuvo deliberadamente preparatoria, esta fase exige entrenar modelos, generar predicciones y sustentar decisiones con evidencia cuantitativa: MSE, RMSE y R^2 se interpretan de manera conjunta para leer precisión, penalización de errores grandes y capacidad explicativa, en línea con el material docente de evaluación de modelos de regresión (Ruete, 2026e).

Elemento	Aplicación al caso
Contexto	Distritos censales de California; se busca estimar el valor mediano de vivienda a partir de variables socioeconómicas y geográficas.
Situación	Necesidad de comparar modelos de regresión supervisada para orientar la mejora del pipeline analítico en fases posteriores.
Datos	20.640 observaciones; 8 predictores numéricos continuos; MedHouseVal continua (target).
Objetivo analítico	Implementar y comparar modelos de regresión, evaluando desempeño mediante MSE, RMSE y R^2 sobre datos de prueba.
Tipo de aprendizaje	Supervisado de regresión: existe una variable objetivo numérica continua observada para cada distrito.

III. Objetivos

Objetivo general

Implementar y comparar modelos de regresión supervisada sobre el dataset California Housing, evaluando su desempeño predictivo mediante MSE, RMSE y R^2 , con el fin de identificar el modelo que ofrece el mejor equilibrio entre ajuste, generalización e interpretabilidad para este problema.

Objetivos específicos

- Preparar el conjunto de datos: revisar calidad, definir X e y, particionar entrenamiento/prueba y aplicar escalamiento de forma selectiva, evitando fuga de información.
- Implementar los tres modelos obligatorios de la fase: Regresión Lineal Simple, Árbol de Decisión para Regresión y Red Neuronal (MLP) para Regresión.
- Incorporar, como análisis complementario, una Regresión Lineal Multivariable y un Random Forest Regressor, sin que sustituyan a los modelos obligatorios.
- Evaluar los cinco modelos mediante MSE, RMSE y R^2 sobre el conjunto de prueba, y contrastar el desempeño en entrenamiento y prueba para identificar sobreajuste.
- Comparar los modelos considerando error, capacidad explicativa, generalización, complejidad e interpretabilidad, y seleccionar el modelo con mejor desempeño entre los obligatorios y, si corresponde, a nivel global.

IV. Descripción del conjunto de datos y preprocesamiento

4.1 Descripción general del dataset

California Housing contiene 20.640 observaciones y 9 columnas: 8 variables predictoras y la variable objetivo MedHouseVal, expresada en cientos de miles de dólares (scikit-learn developers, s. f.-d). Cada fila representa un distrito censal, no una vivienda individual; las variables corresponden a promedios o medianas calculadas sobre ese distrito.

Variable	Rol	Descripción
MedInc	Predictora	Ingreso mediano del distrito (decenas de miles de USD).
HouseAge	Predictora	Antigüedad media de las viviendas.
AveRooms	Predictora	Habitaciones promedio por vivienda.
AveBedrms	Predictora	Dormitorios promedio por vivienda.
Population	Predictora	Población del distrito.
AveOccup	Predictora	Ocupantes promedio por hogar.
Latitude	Predictora	Latitud del distrito.
Longitude	Predictora	Longitud del distrito.
MedHouseVal	Objetivo	Valor mediano de vivienda (cientos de miles de USD).

4.2 Calidad de datos

La revisión de calidad sobre las 20.640 observaciones no detecta valores nulos ni registros duplicados exactos en ninguna de las 9 columnas. La revisión de valores extremos (criterio $|z| > 3$) identifica outliers principalmente en MedInc (345 casos, 1,67%), Population (342, 1,66%), AveBedrms (145, 0,70%) y AveRooms (133, 0,64%), y de forma marginal en AveOccup (8, 0,04%); HouseAge, Latitude y Longitude no presentan outliers bajo este criterio. Estos valores corresponden a distritos censales reales — de ingreso

muy alto o de densidad poco habitual — y no a errores de captura, por lo que se documentan pero no se eliminan.

4.3 Definición de X/y, partición y escalamiento

Las 8 variables predictoras se separan en X y MedHouseVal en y. El dataset se particiona en 80% entrenamiento y 20% prueba mediante `train_test_split`, con `random_state=42` para reproducibilidad; el conjunto de prueba queda reservado exclusivamente para la evaluación final.

Objeto	Dimensión	Descripción
X	(20640, 8)	Matriz de predictores.
y	(20640,)	Vector de la variable objetivo MedHouseVal.
X_train / y_train	(16512, 8) / (16512,)	Datos usados para entrenar los modelos.
X_test / y_test	(4128, 8) / (4128,)	Datos reservados para evaluar generalización.

Respecto del escalamiento, la Regresión Lineal ordinaria no requiere obligatoriamente estandarizar las variables: sus coeficientes y su desempeño predictivo no dependen de la escala de los predictores. En este análisis se estandarizan las variables para la Regresión Lineal Multivariable, por consistencia del pipeline y para que la magnitud de los coeficientes sea comparable entre predictores, y no como un requisito metodológico del modelo. El escalamiento resulta especialmente relevante para la Red Neuronal MLP, que se optimiza mediante descenso de gradiente y se beneficia de variables en escalas homogéneas para converger de forma estable. El Árbol de Decisión y Random Forest no requieren escalamiento, porque dividen el espacio de predictores evaluando umbrales por variable; el orden relativo de los valores no cambia al escalar.

El `StandardScaler` se ajusta (fit) únicamente con X_train y se aplica (transform) tanto a X_train como a X_test, evitando que información del conjunto de prueba influya en el preprocesamiento (fuga de información o data leakage). La misma partición se reutiliza en los cinco modelos, de modo que la comparación final entre ellos sea válida.

V. Análisis exploratorio orientado al modelamiento

El análisis exploratorio se concentra en la evidencia que sustenta decisiones de modelamiento posteriores: la distribución de la variable objetivo, las correlaciones entre predictores y target, y la relación entre el predictor seleccionado para la Regresión Lineal Simple y MedHouseVal.




Figura 1. Distribución de las variables del dataset, incluida la variable objetivo. Fuente: elaboración propia a partir del notebook F2_Regresion.ipynb.

MedHouseVal está truncada en 5,00001 (tope censal del valor de vivienda), lo que genera una acumulación de observaciones en ese valor máximo. AveRooms, AveBedrms, Population y AveOccup muestran colas largas hacia la derecha, mientras Latitude/Longitude reflejan la bimodalidad geográfica de California (Los Ángeles y la Bahía de San Francisco).




Figura 2. Matriz de correlación entre las variables del dataset. Fuente: elaboración propia a partir del notebook *F2_Regresion.ipynb*.

MedInc es el predictor con mayor correlación con MedHouseVal ($r \approx 0,688$), seguido de AveRooms ($r \approx 0,152$) y Latitude ($r \approx -0,144$). Latitude y Longitude muestran correlación lineal moderada-baja porque su relación con el precio es geográfica, no monótonica; la correlación de Pearson subestima su relevancia real, como se confirma más adelante en los coeficientes del modelo multivariable (Sección IX) y en la importancia de variables de los modelos de árboles (Secciones VII y IX).




Figura 3. Relación entre MedInc y MedHouseVal. Fuente: elaboración propia a partir del notebook *F2_Regresion.ipynb*.

El gráfico de dispersión muestra una relación positiva y razonablemente lineal entre MedInc y MedHouseVal, consistente con la correlación observada. Esta evidencia — mayor correlación con el target y relación visualmente más lineal — es la que respalda la selección de MedInc como predictor único de la Regresión Lineal Simple en la Sección VI.

VI. Modelo de regresión lineal simple

Modelo obligatorio.

6.1 Fundamento y variable seleccionada

La Regresión Lineal Simple estima la variable continua Y mediante $\hat{Y} = \beta_0 + \beta_1 \cdot X$, usando un único predictor X . Se emplea como modelo base, altamente interpretable, antes de incorporar predictores adicionales o modelos no lineales (Rue, 2026a; Draper & Smith, 1998). El coeficiente β_1 se interpreta como una asociación predictiva, no como una relación causal.

El predictor seleccionado es MedInc, con base en la evidencia del análisis exploratorio (Sección V): es la variable con mayor correlación de Pearson con MedHouseVal y la que exhibe la relación más lineal en el gráfico de dispersión. MedInc se utiliza sin escalar: al tratarse de un único predictor, el escalamiento no altera el ajuste del modelo ni su R^2 , y mantenerlo en su unidad original facilita interpretar directamente el coeficiente estimado.

6.2 Entrenamiento y evidencia de ejecución

El modelo se entrena con `LinearRegression()` sobre `X_train` limitado a la columna MedInc y `y_train`. El intercepto y la pendiente obtenidos son:

Parámetro	Valor
Intercepto (β_0)	0,4446
Pendiente (β_1)	0,4193
Ecuación estimada	MedHouseVal = 0,4446 + 0,4193 · MedInc

6.3 Predicciones y métricas de desempeño

Métrica	Prueba (test)	Entrenamiento
MSE	0,7091	—
RMSE	0,8421	—
R^2	0,4589	0,4770




Figura 4. Recta ajustada de Regresión Lineal Simple ($MedInc \rightarrow MedHouseVal$) sobre el conjunto de prueba. Fuente: elaboración propia a partir del notebook *F2_Regresion.ipynb*.

6.4 Interpretación

La pendiente positiva confirma que, en promedio, un mayor ingreso mediano del distrito se asocia a un mayor valor mediano de vivienda, consistente con la correlación observada en la Sección V. El R^2 de prueba (0,4589) indica que este único predictor explica cerca del 46% de la variabilidad de $MedHouseVal$; al usar solo una variable, queda un margen de error considerable, coherente con la dispersión creciente en distritos de mayor ingreso observada en el gráfico de dispersión. El R^2 de entrenamiento (0,4770) y de prueba (0,4589) son similares entre sí, lo que indica que el modelo no está sobreajustado — esperable dada su baja flexibilidad. Este resultado funciona como línea base frente a los modelos de las secciones siguientes.

VII. Modelo de árboles de decisión para regresión

Modelo obligatorio.

7.1 Fundamento

Un árbol de regresión no asume una relación lineal global: divide recursivamente el espacio de predictores en regiones y asigna a cada hoja el promedio de $MedHouseVal$ de las observaciones que caen en ella, lo que le permite capturar no linealidades e interacciones que la Regresión Lineal no representa directamente (Ruete, 2026b; Hastie et al., 2009; scikit-learn developers, s. f.-b). Su principal riesgo es la alta varianza: un árbol demasiado profundo memoriza el entrenamiento y generaliza mal. Existe, por tanto, un compromiso entre profundidad, complejidad y la relación sesgo/varianza — un árbol poco profundo tiende a subajustar, mientras uno muy profundo tiende a sobreajustar.

El árbol se entrena sobre las variables sin escalar (Sección IV), dado que dividir por umbrales no depende de la escala de las variables.

7.2 Selección de max_depth mediante validación interna

El hiperparámetro central que controla la complejidad del árbol es max_depth. Su valor no se selecciona observando el desempeño sobre $X_{\text{test}}/y_{\text{test}}$, porque usar el conjunto de prueba para elegir un hiperparámetro produce una estimación optimista del desempeño real (una forma de fuga de información). En su lugar, se separa una partición de validación interna a partir de $X_{\text{train}}/y_{\text{train}}$ (80% entrenamiento interno / 20% validación, random_state=42): se entrena el árbol con distintas profundidades usando solo el entrenamiento interno y se evalúa cada una sobre la validación.




Figura 5. R^2 de entrenamiento interno y de validación por profundidad del árbol. Fuente: elaboración propia a partir del notebook F2_Regresion.ipynb.

La profundidad con mayor R^2 de validación es 9 (R^2 de validación = 0,6870). Ni X_{test} ni y_{test} participan en esta decisión; una vez fijado max_depth=9, el árbol final se reentrena con todo $X_{\text{train}}/y_{\text{train}}$ y se evalúa una única vez sobre X_{test} .

7.3 Métricas de desempeño

Métrica	Prueba (test)	Entrenamiento
MSE	0,4151	—
RMSE	0,6443	—
R^2	0,6833	0,7999

7.4 Interpretación

El R^2 de entrenamiento (0,7999) es mayor que el de prueba (0,6833) — una brecha de 0,117 —, lo que evidencia algo de sobreajuste residual incluso con la profundidad seleccionada por validación, esperable en un único árbol. Aun así, el R^2 de prueba del árbol supera ampliamente al de la Regresión Lineal Simple (0,4589), lo que respalda que el precio de vivienda depende de relaciones no lineales e interacciones que un modelo lineal de un predictor no captura. La importancia de variables confirma a MedInc como el

predictor con mayor peso en las divisiones del árbol (0,632), seguido de AveOccup (0,132), Latitude (0,075) y Longitude (0,059).

VIII. Modelo de redes neuronales para regresión

Modelo obligatorio.

8.1 Arquitectura e hiperparámetros

Un MLPRegressor (Perceptrón Multicapa) puede capturar relaciones no lineales complejas mediante una capa de entrada (los 8 predictores), una o más capas ocultas de neuronas interconectadas con pesos y sesgos ajustables, y una capa de salida continua. El entrenamiento se basa en forward propagation, una función de pérdida, backpropagation y optimización iterativa de los pesos (Rue, 2026d; Géron, 2019; scikit-learn developers, s. f.-c).

Hiperparámetro	Valor	Función
hidden_layer_sizes	(100,)	Una capa oculta de 100 neuronas.
activation	relu	Función de activación no lineal en la capa oculta.
solver	adam	Algoritmo de optimización del descenso de gradiente.
max_iter	500	Máximo de iteraciones de entrenamiento.
early_stopping	True	Detiene el entrenamiento si el error de validación deja de mejorar.
random_state	42	Reproducibilidad de la inicialización de pesos.

8.2 Escalamiento y entrenamiento

A diferencia de los modelos basados en árboles, el MLP se beneficia especialmente del escalamiento de las variables: al optimizarse mediante métodos iterativos basados en gradiente, variables en escalas muy diferentes pueden dificultar o ralentizar la convergencia. Por ello se utilizan `X_train_scaled` y `X_test_scaled`, obtenidos mediante un escalador ajustado exclusivamente con los datos de entrenamiento (Sección IV).

El entrenamiento ejecutó 153 iteraciones de un máximo de 500 permitidas, con una función de pérdida final de 0,1386. Que el entrenamiento se haya detenido antes del máximo es señal de que `early_stopping` actuó como mecanismo de control de sobreajuste.

8.3 Métricas de desempeño

Métrica	Prueba (test)	Entrenamiento
MSE	0,3017	—
RMSE	0,5493	—
R ²	0,7697	0,7898

8.4 Interpretación

El MLP no ofrece coeficientes ni importancia de variables interpretables directamente; su evaluación se basa exclusivamente en las métricas de desempeño. Con R^2 de prueba = 0,7697 y RMSE = 0,5493, el MLP es el modelo con mejor desempeño entre los tres obligatorios, superando al Árbol de Decisión (0,6833) y a la Regresión Lineal Simple (0,4589): su capacidad de modelar no linealidades sí se tradujo en una mejora de desempeño en este dataset. La brecha entre el R^2 de entrenamiento (0,7898) y de prueba (0,7697) es de apenas 0,020 — la más pequeña entre los cinco modelos evaluados —, lo que indica que `early_stopping` fue efectivo para controlar el sobreajuste. La principal limitación del modelo es su baja interpretabilidad frente a los modelos lineales y al árbol.

IX. Análisis complementario

Además de los tres modelos obligatorios, se conservan dos modelos complementarios que ya estaban correctamente implementados en el notebook y que enriquecen la comparación: no sustituyen a los modelos obligatorios, sino que permiten dimensionar cuánto aporta incorporar más información (Regresión Lineal Multivariable) o mayor capacidad de modelamiento no lineal (Random Forest).

9.1 Regresión Lineal Multivariable

Se incorporan los 8 predictores simultáneamente y las variables se estandarizan, de modo que cada coeficiente sea comparable en magnitud. Sobre el conjunto de prueba se obtiene MSE = 0,5559, RMSE = 0,7456 y R^2 = 0,5758 (R^2 de entrenamiento = 0,6126). El R^2 de prueba supera claramente al de la Regresión Lineal Simple (0,4589), lo que cuantifica el aporte de los 7 predictores adicionales. Los coeficientes de mayor magnitud corresponden a Latitude (-0,897) y Longitude (-0,870), muy cerca de MedInc (0,854): la ubicación geográfica pesa tanto como el ingreso una vez que todas las variables se estiman conjuntamente, lo que confirma que la correlación lineal simple (Sección V) subestimaba la relevancia real de la latitud y la longitud.

9.2 Random Forest

Random Forest combina múltiples árboles de decisión entrenados sobre submuestras bootstrap y subconjuntos aleatorios de variables, promediando sus predicciones (Breiman, 2001; Ruete, 2026c). Se entrena con `n_estimators=300`, `max_depth=None` y `random_state=42`, sin escalamiento por la misma razón que el Árbol de Decisión. Sobre el conjunto de prueba se obtiene MSE = 0,2534, RMSE = 0,5034 y R^2 = 0,8066 — el mejor resultado entre los cinco modelos evaluados —, con un R^2 de entrenamiento de 0,9744. La brecha train/test (0,167) es la mayor de los cinco modelos, esperable dado que cada árbol individual puede ajustar fuertemente sus muestras bootstrap; pese a ello, su R^2 de prueba sigue siendo el más alto. La importancia de variables confirma a MedInc (0,526) y AveOccup (0,138) como los predictores más relevantes, en línea con lo observado en el Árbol de Decisión.

X. Evaluación y comparación de modelos

La siguiente tabla reúne las métricas de los cinco modelos entrenados, calculadas exclusivamente a partir del notebook final. Los tres primeros corresponden a los modelos obligatorios de esta fase; los dos últimos son análisis complementario.

Modelo	Tipo	MSE	RMSE	R ²
Random Forest	Complementario	0,2534	0,5034	0,8066
Red Neuronal (MLP)	Obligatorio	0,3017	0,5493	0,7697
Árbol de Decisión	Obligatorio	0,4151	0,6443	0,6833
Regresión Lineal Multivariable	Complementario	0,5559	0,7456	0,5758
Regresión Lineal Simple	Obligatorio	0,7091	0,8421	0,4589

Tabla. Reporte tabulado de métricas de regresión sobre el conjunto de prueba, ordenado de mayor a menor R². Fuente: elaboración propia a partir del notebook F2_Regresion.ipynb.




Figura 6. RMSE, R² de prueba y comparación R² entrenamiento/prueba por modelo. Fuente: elaboración propia a partir del notebook F2_Regresion.ipynb.

El MSE queda expresado en unidades al cuadrado y no debe leerse directamente en las unidades originales de MedHouseVal; el RMSE, al volver a esas unidades (cientos de miles de USD), resulta más útil para una interpretación práctica del error típico. Un R² más alto indica mayor proporción de variabilidad explicada, pero por sí solo no demuestra que un modelo sea mejor (Ruete, 2026e; Hastie et al., 2009): debe leerse junto con el RMSE, la brecha entre R² de entrenamiento y de prueba (que evidencia sobreajuste), los residuos y la complejidad e interpretabilidad de cada modelo.

El desempeño mejora de forma consistente a medida que el modelo incorpora más información o mayor capacidad de modelamiento no lineal: la Regresión Lineal Simple es superada por el Árbol de Decisión y por la Red Neuronal, y ambos modelos complementarios (Multivariable y Random Forest) se ubican en los extremos de ese mismo patrón — el primero por debajo del árbol al usar solo información lineal, y el segundo por encima de todos al combinar no linealidad con reducción de varianza mediante ensamble.

XI. Selección del modelo

Bajo la partición y configuración evaluadas en este notebook, Random Forest (análisis complementario) obtuvo el mejor desempeño global, con el R² de prueba más alto (0,8066) y el RMSE más bajo (0,5034)

entre los cinco modelos. Dentro de los modelos analizados que sí son obligatorios para esta fase, la Red Neuronal (MLP) presentó el mejor desempeño ($R^2 = 0,7697$, $RMSE = 0,5493$), seguida por el Árbol de Decisión ($R^2 = 0,6833$) y, en último lugar, la Regresión Lineal Simple ($R^2 = 0,4589$), coherente con su naturaleza de modelo base con un único predictor.

Random Forest y el MLP muestran una brecha train/test mayor que el Árbol de Decisión y la Regresión Lineal, lo que indica más varianza interna; aun así, ambos generalizan mejor que las alternativas más simples sobre el conjunto de prueba. Si el criterio de decisión priorizara la interpretabilidad de coeficientes por sobre el error de predicción, la Regresión Lineal seguiría siendo preferible pese a su menor precisión — una decisión de negocio, no solo estadística. Esta conclusión es válida para esta partición train/test y esta configuración de hiperparámetros, y podría variar con otra partición o con una búsqueda de hiperparámetros más exhaustiva.

XII. Diagnóstico y limitaciones

12.1 Diagnóstico




Figura 7. Valores reales vs. predichos y residuos por modelo, sobre el conjunto de prueba. Fuente: elaboración propia a partir del notebook F2_Regresion.ipynb.

En un modelo bien ajustado, los puntos de real vs. predicho se concentran cerca de la diagonal, y los residuos se distribuyen de forma aleatoria alrededor de cero. La franja diagonal visible en varios modelos corresponde al techo censal de MedHouseVal en 5,00001: ningún modelo puede predecir valores mayores porque nunca los observó como tales durante el entrenamiento, y los distritos truncados generan residuos sistemáticamente negativos en esa zona. La dispersión de los residuos de la Regresión Lineal Simple es notoriamente mayor que la de los demás modelos, coherente con que usa un único predictor.

12.2 Limitaciones

- Techo censal de MedHouseVal (5,00001): infla el error de todos los modelos por igual en el extremo superior de la distribución.
- Ausencia de variables estructurales (calidad de vivienda, características del vecindario más allá de ubicación y ocupación) que limitan el techo de desempeño alcanzable.

- Sin validación cruzada: las métricas provienen de una única partición train/test; una validación k-fold daría una estimación más robusta de la variabilidad del desempeño.
- Hiperparámetros no exhaustivamente optimizados más allá de max_depth del árbol (seleccionado por validación interna); el desempeño de MLP y Random Forest podría mejorar con una búsqueda sistemática.
- Las asociaciones reportadas (correlación, coeficientes, importancia de variables) son de naturaleza predictiva, no causal: no permiten afirmar que un mayor ingreso cause un mayor valor de vivienda.

XIII. Notebook y trazabilidad

El notebook F2_Regresion.ipynb constituye la evidencia computacional reproducible de esta fase: contiene el código, su ejecución y los resultados numéricos citados en este informe. El informe no reproduce el código; explica qué se hizo, para qué y qué resultado produjo, remitiendo al notebook como fuente de la evidencia técnica.

Bloque	Propósito	Evidencia generada
Carga de datos	Obtener California Housing como DataFrame.	20.640 filas x 9 columnas; sin nulos ni duplicados.
EDA orientado al modelamiento	Identificar el predictor con mayor asociación con el target.	Correlaciones, distribución del target, dispersión MedInc–MedHouseVal.
Preprocesamiento	Definir X/y, partición train/test y escalamiento selectivo.	Dimensiones de X_train/X_test; StandardScaler ajustado solo en train.
Regresión Lineal Simple	Modelo base obligatorio con MedInc.	Intercepto, pendiente, MSE, RMSE, R ² .
Árbol de Decisión	Modelo obligatorio con selección de max_depth por validación.	Curva train/validación, max_depth=9, MSE, RMSE, R ² .
Red Neuronal (MLP)	Modelo obligatorio no lineal.	Iteraciones, pérdida final, MSE, RMSE, R ² .
Modelos complementarios	Regresión Multivariable y Random Forest.	Coeficientes, importancia de variables, MSE, RMSE, R ² .
Evaluación y diagnóstico	Consolidar métricas y analizar residuos.	Tabla comparativa, gráficos real vs. predicho y residuos.

XIV. Repositorio

El repositorio grupal utilizado en la Fase 1 se mantiene para la Fase 2, sin rediseñar su estructura:

Repositorio: https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

Notebook: notebooks/F2_Regresion.ipynb

Informe: docs/MCDI504_S2_1_GRUPOX.pdf

El informe, el notebook y el repositorio forman parte de un mismo flujo de trabajo: el informe argumenta, el notebook ejecuta y el repositorio conserva ambos junto con la evidencia visual. Antes de la entrega definitiva corresponde verificar que las tres piezas describan la misma secuencia de modelos, hiperparámetros y resultados, y ejecutar el notebook mediante Restart Kernel + Run All.

XV. Conclusiones

Esta fase abordó la predicción de MedHouseVal, el valor mediano de vivienda por distrito censal de California, a partir de variables socioeconómicas y geográficas. Se implementaron los tres modelos exigidos por la pauta — Regresión Lineal Simple, Árbol de Decisión para Regresión y Red Neuronal (MLP) — junto con dos modelos complementarios, Regresión Lineal Multivariable y Random Forest, que permiten dimensionar cuánto aporta incorporar más información o mayor capacidad de modelamiento no lineal.

Los resultados muestran una mejora consistente del desempeño a medida que el modelo incorpora más información o mayor capacidad no lineal: la Regresión Lineal Simple ($R^2 = 0,4589$) es superada por el Árbol de Decisión ($R^2 = 0,6833$) y por la Red Neuronal ($R^2 = 0,7697$), el mejor modelo entre los obligatorios; Random Forest, como análisis complementario, obtuvo el mejor resultado global ($R^2 = 0,8066$). Esta evidencia respalda que la relación entre las características del distrito y el valor de vivienda no es puramente lineal.

MedInc emerge como uno de los predictores individuales más informativos dentro de los modelos evaluados, a través de evidencia convergente (correlación de Pearson, coeficiente de los modelos lineales e importancia de variables en los modelos de árboles); la ubicación geográfica y la ocupación promedio por hogar también muestran una asociación relevante, especialmente en el modelo multivariable. Estas asociaciones son de naturaleza predictiva, no causal.

Entre las limitaciones detectadas destacan el techo censal de MedHouseVal, la ausencia de validación cruzada y la falta de una búsqueda sistemática de hiperparámetros más allá de la validación interna aplicada al árbol. Para la continuidad del proyecto se recomienda incorporar validación cruzada, ampliar la búsqueda de hiperparámetros sobre el modelo o los modelos con mejor desempeño, y evaluar variables derivadas de Latitude/Longitude que puedan capturar mejor el componente geográfico.

XVI. Uso de fuentes, citación y referencias

Las decisiones conceptuales y técnicas se sustentan en material docente, documentación oficial y literatura académica, con correspondencia exacta entre las citas del texto y el listado siguiente, tal como se verificó en el notebook final.

Material docente de la asignatura

- Ruete, D. (2026a). Regresión lineal simple, polinomial y multivariable [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026b). Regresión con árboles de decisión [Apunte]. Universidad Andrés Bello.

- Ruete, D. (2026c). Regresión con Random Forest [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026d). Regresión con redes neuronales artificiales [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026e). Evaluación de modelos de regresión [Apunte]. Universidad Andrés Bello.
- Ruete, D. (2026f). Modelos de aprendizaje supervisado - Regresión [Apunte]. Universidad Andrés Bello.

Documentación técnica oficial

- scikit-learn developers. (s. f.-a). LinearRegression. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html
- scikit-learn developers. (s. f.-b). DecisionTreeRegressor. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html>
- scikit-learn developers. (s. f.-c). MLPRegressor. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html
- scikit-learn developers. (s. f.-d). California Housing dataset. Scikit-learn documentation. https://scikit-learn.org/stable/datasets/real_world.html#california-housing-dataset

Literatura académica complementaria

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Draper, N. R., & Smith, H. (1998). *Applied regression analysis* (3rd ed.). Wiley.
- Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.

XVII. Anexos

Anexo A. Checklist de alineación con la rúbrica

Criterio de rúbrica	Evidencia incluida en el informe
Introducción y contextualización	Contexto, situación de análisis, objetivo analítico y relación con la variable continua (Sección II).
Dataset y preprocesamiento	Variables, calidad de datos, X/y, train/test, escalamiento selectivo y justificación (Sección IV).
Regresión Lineal Simple	Modelo, predictor, ejecución, resultados e interpretación (Sección VI).
Árbol de Decisión	Hiperparámetros, validación interna, ejecución, resultados e interpretación (Sección VII).
Red Neuronal	Arquitectura, hiperparámetros, ejecución, resultados e interpretación (Sección VIII).

Criterio de rúbrica	Evidencia incluida en el informe
Evaluación (MSE/RMSE/R ²)	Reporte tabulado de los cinco modelos con identificación de tipo (Sección X).
Comparación de modelos	Ventajas, limitaciones, mejor modelo obligatorio y global, justificación (Secciones X–XI).
Notebook y documentación	Trazabilidad entre notebook, informe y repositorio (Sección XIII).
Conclusiones	Síntesis de resultados, evidencia, limitaciones y continuidad (Sección XV).
Fuentes APA	Fuentes docentes, documentación técnica oficial y literatura académica (Sección XVI).

Anexo B. Diccionario de variables

Variable	Tipo	Uso
MedInc	Numérica continua	Predictor (único predictor de la Regresión Lineal Simple).
HouseAge	Numérica continua	Predictor.
AveRooms	Numérica continua	Predictor.
AveBedrms	Numérica continua	Predictor.
Population	Numérica continua	Predictor.
AveOccup	Numérica continua	Predictor.
Latitude	Numérica continua	Predictor.
Longitude	Numérica continua	Predictor.
MedHouseVal	Numérica continua	Variable objetivo.