

MCDI504

MACHINE LEARNING I

AVANCE DEL PROYECTO - FASE 3:

DESARROLLO DEL PROYECTO

Integrantes: Enzo Pinilla · Claudio Alarcón · Luis Rodrigo Espinoza

Curso: MCDI504 - Machine Learning I

Docente: David Ruete Zúñiga

Grupo: 2

Fecha: 23 de agosto de 2026

Repositorio: https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

I. Tabla de contenido

II.	<i>Descripción del conjunto de datos y preparación para clasificación</i>	3
2.1	Variables predictoras seleccionadas	3
2.2	Preparación analítica y partición entrenamiento/prueba	4
III.	<i>Análisis exploratorio inicial del conjunto de datos</i>	4
3.1	Distribución de clases	4
3.2	Calidad de datos	5
3.3	Patrones preliminares y relación con la clasificación	6
IV.	<i>Notebook F3_Clasificacion.ipynb</i>	7
V.	<i>Modelo KNN</i>	7
VI.	<i>Modelo de árbol de decisión</i>	8
VII.	<i>Modelo SVM</i>	9
VIII.	<i>Modelo Naïve Bayes</i>	10
IX.	<i>Evaluación preliminar de modelos de clasificación</i>	11
9.1	Interpretación comparativa	12
X.	<i>Conclusiones</i>	13
XI.	<i>XI. Uso de fuentes, citación y referencias</i>	13
XII.	<i>Anexos</i>	14
	Anexo A. Detalle de las matrices de confusión	14
	Anexo B. Fragmentos esenciales del pipeline	14

II. Descripción del conjunto de datos y preparación para clasificación

El avance utiliza el dataset Titanic cargado mediante seaborn. El objetivo analítico es predecir si un pasajero sobrevivió al naufragio a partir de variables demográficas, socioeconómicas y de viaje. La variable objetivo es survived, codificada como 0 (no sobrevivió) y 1 (sobrevivió), por lo que se trata de un problema de aprendizaje supervisado de clasificación binaria. La actividad exige que la preparación, el notebook, los modelos y el informe formen un flujo coherente y trazable (Universidad Andrés Bello, 2026a).

Elemento	Descripción aplicada al caso
Dataset	Titanic, cargado con <code>seaborn.load_dataset("titanic")</code> .
Observaciones iniciales	891 registros.
Columnas iniciales	15 variables.
Variable objetivo	survived: 0 = no sobrevivió; 1 = sobrevivió.
Propósito	Predecir la supervivencia y comparar cuatro clasificadores supervisados.
Modelos evaluados	KNN, Árbol de Decisión, SVM y Naïve Bayes.

Tabla 1. Descripción general del conjunto de datos y propósito analítico.

2.1 Variables predictoras seleccionadas

Después de eliminar columnas redundantes o con demasiados valores faltantes y aplicar codificación one-hot, la matriz de características queda compuesta por ocho predictores. Esta selección evita incluir alive, que replica directamente el resultado de survived y produciría fuga de información hacia el modelo.

Variable	Rol	Descripción
pclass	Predictora	Clase del pasaje (1ª, 2ª o 3ª); aproxima nivel socioeconómico.
age	Predictora	Edad; 177 faltantes imputados con la mediana (28,0).
sibsp	Predictora	Número de hermanos o cónyuges a bordo.
parch	Predictora	Número de padres o hijos a bordo.
fare	Predictora	Tarifa pagada por el pasaje.
sex_male	Predictora codificada	Indicador binario generado desde sex.
embarked_Q	Predictora codificada	Indicador de embarque en Queenstown.
embarked_S	Predictora codificada	Indicador de embarque en Southampton.
survived	Objetivo	Clase a predecir: 0 o 1.

Tabla 2. Variables utilizadas en el problema de clasificación.

2.2 Preparación analítica y partición entrenamiento/prueba

La preparación conserva el flujo del cuaderno docente de la semana 3 y lo documenta explícitamente. El conjunto procesado queda con 9 columnas: 8 predictores y la variable objetivo. La partición utiliza 80% para entrenamiento y 20% para prueba, con `random_state=42`, resultando en 712 observaciones de entrenamiento y 179 de prueba (Universidad Andrés Bello, 2026b).

Acción	Implementación	Justificación
Eliminación de columnas	<code>deck, class, who, adult_male, embark_town, alive, alone</code>	deck tiene ~77% de faltantes; las demás son redundantes, derivables o duplican información.
Imputación de age	Mediana = 28,0	Conserva registros y es robusta frente a valores extremos.
Imputación de embarked	Moda = S	Solo faltan 2 registros; se usa la categoría más frecuente.
Codificación	<code>pd.get_dummies(..., drop_first=True)</code>	Convierte categorías nominales a indicadores binarios sin imponer orden.
Definición X / y	X = predictores; y = survived	Separa características y etiqueta objetivo.
Partición	<code>test_size=0.20; random_state=42</code>	Reserva datos no vistos y hace reproducible la partición.
Escalamiento SVM	<code>StandardScaler: fit en X_train, transform en X_test</code>	Evita fuga de información y ajusta escalas para un modelo sensible a distancias.

Tabla 3. Preparación de datos y justificación metodológica.

El escalamiento se aplica a SVM porque su geometría depende de la escala de las características. KNN se conserva sin escalamiento para reproducir la configuración entregada por el docente; Esta decisión debe considerarse al interpretar los resultados, ya que KNN también es sensible a la escala de las variables (scikit-learn Developers, s. f.-a, s. f.-e).

III. Análisis exploratorio inicial del conjunto de datos

El análisis exploratorio se orienta a fundamentar la preparación del problema de clasificación: distribución de clases, calidad de datos y patrones descriptivos de variables relevantes. La evidencia es descriptiva y no se interpreta como causalidad.

3.1 Distribución de clases

Clase	Código	Frecuencia	Porcentaje
No sobrevivió	0	549	61,62%
Sobrevivió	1	342	38,38%
Total	—	891	100,00%

Tabla 4. Distribución de la variable objetivo survived.




Figura 1. Distribución de la variable objetivo survived.

Existe un desbalance moderado: 61,62% de las observaciones pertenecen a la clase 0 y 38,38% a la clase 1. Por ello, Accuracy no debe utilizarse de manera aislada; Precision, Recall, F1-score y la matriz de confusión permiten evaluar mejor el comportamiento sobre la clase sobrevivió.

3.2 Calidad de datos

Variable	Faltantes	Porcentaje	Tratamiento
deck	688	77,22%	Eliminación de la variable.
age	177	19,87%	Imputación con mediana (28,0).
embarked	2	0,22%	Imputación con moda (S).

Tabla 5. Valores faltantes relevantes y tratamiento aplicado.




Figura 2. Valores faltantes en el dataset original.

Eliminar deck evita imputar aproximadamente tres cuartas partes de una variable. En cambio, age y embarked conservan información potencialmente útil y pueden completarse con estrategias simples y documentadas. Tras el preprocesamiento no quedan valores faltantes en las variables utilizadas para modelar.

3.3 Patrones preliminares y relación con la clasificación

Variable / grupo	Tasa de supervivencia
Mujeres	74,20%
Hombres	18,89%
1ª clase	62,96%
2ª clase	47,28%
3ª clase	24,24%

Tabla 6. Patrones descriptivos seleccionados antes del modelamiento.

Las diferencias descriptivas por sexo y clase de pasaje sugieren que sex y pclass pueden aportar señal para separar las clases. age, fare, sibsp y parch incorporan información demográfica, económica y familiar adicional. Estas diferencias justifican su consideración como predictores, pero su aporte efectivo debe juzgarse con desempeño fuera de muestra y no mediante asociaciones descriptivas aisladas.

IV. Notebook F3_Clasificacion.ipynb

El archivo F3_Clasificacion.ipynb constituye la evidencia técnica principal del avance. Está organizado en un flujo secuencial con celdas narrativas, código ejecutable y resultados, y fue verificado mediante una ejecución completa sin errores. El notebook registra versiones del entorno y utiliza un respaldo embebido del mismo dataset Titanic para permitir reproducción aun cuando seaborn no pueda descargar los datos.

Etapas	Evidencia en el notebook	Correspondencia en informe
Definición del problema	Variable objetivo, clases y propósito	Sección II
Carga / comprensión	Dimensiones, tipos, primeras filas	Secciones II–III
EDA	Frecuencias, faltantes, tasas descriptivas	Sección III
Preprocesamiento	drop, fillna, get_dummies, X/y	Sección II
Partición	train_test_split(80/20, random_state=42)	Sección II
KNN	Ficha, fit, predict, métricas, matriz	Sección V
Árbol	Ficha, fit, predict, métricas, matriz	Sección VI
SVM	StandardScaler + SVC, métricas, matriz	Sección VII
Naïve Bayes	GaussianNB, métricas, matriz	Sección VIII
Comparación	Tabla consolidada y gráfico de métricas	Sección IX
Cierre	Fortalezas, limitaciones, conclusión y checklist	Secciones IX–XII

Tabla 7. Trazabilidad entre notebook e informe.

Repositorio del grupo: https://github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2.

V. Modelo KNN

k-Nearest Neighbors (KNN) es un clasificador basado en proximidad: asigna la clase predominante entre los k vecinos más cercanos. Se configura con cinco vecinos y distancia Minkowski con $p=2$, equivalente a distancia euclidiana (scikit-learn Developers, s. f.-a).

Parámetro	Valor	Interpretación
n_neighbors	5	Se consideran cinco vecinos.
metric	minkowski	Métrica general de distancia.
p	2	Equivale a distancia euclidiana.
Datos	X_train / X_test sin escalar	Reproduce el experimento docente; se documenta como limitación.

Tabla 8. Ficha técnica mínima del modelo KNN.

Accuracy	Precision	Recall	F1-score	Matriz de confusión
0,6983	0,6786	0,5135	0,5846	[[87, 18], [36, 38]]

Tabla 9. Resultados del modelo KNN en el conjunto de prueba.




Figura 3. Matriz de confusión del modelo KNN.

KNN obtiene el desempeño más bajo de los cuatro modelos: Accuracy = 0,6983 y F1-score = 0,5846. La matriz presenta 36 falsos negativos y solo 38 verdaderos positivos para la clase sobrevivió, lo que explica su Recall reducido (0,5135). Dado que KNN depende de distancias y fue entrenado sin estandarización, su desempeño debe interpretarse considerando esta condición.

VI. Modelo de árbol de decisión

El Árbol de Decisión clasifica mediante reglas jerárquicas que dividen el espacio de características. El criterio Gini mide la calidad de las divisiones y max_depth=5 limita la profundidad para controlar complejidad (scikit-learn Developers, s. f.-b).

Parámetro	Valor	Interpretación
criterion	gini	Criterio de impureza utilizado para cada división.
max_depth	5	Limita la complejidad del árbol.
random_state	42	Fija el componente aleatorio de la construcción.
Datos	X_train / X_test	No requiere estandarización por distancia.

Tabla 10. Ficha técnica mínima del Árbol de Decisión.

Accuracy	Precision	Recall	F1-score	Matriz de confusión
0,7989	0,8276	0,6486	0,7273	[[95, 10], [26, 48]]

Tabla 11. Resultados del Árbol de Decisión en el conjunto de prueba.




Figura 4. Matriz de confusión del Árbol de Decisión.

El árbol mejora claramente a KNN: alcanza Accuracy = 0,7989 y Precision = 0,8276. Registra solo 10 falsos positivos, aunque mantiene 26 falsos negativos, por lo que su Recall (0,6486) es menor que el de SVM y Naïve Bayes. Su fortaleza principal es la interpretabilidad; sin embargo, los resultados corresponden específicamente a la configuración utilizada con max_depth=5.

VII. Modelo SVM

Support Vector Machine (SVM) busca una frontera que maximiza el margen entre clases. Se emplea un kernel RBF para permitir una frontera no lineal y C=1 como nivel de regularización. Las variables se estandarizan con StandardScaler ajustado únicamente sobre entrenamiento para evitar fuga de información (scikit-learn Developers, s. f.-c, s. f.-e).

Parámetro	Valor	Interpretación
kernel	rbf	Permite una frontera de decisión no lineal.
C	1	Equilibra margen y penalización de errores.
random_state	42	Parámetro registrado en la implementación; con probability=False el ajuste es determinista.
Escalamiento	StandardScaler	fit en X_train y transform en X_test.

Tabla 12. Ficha técnica mínima del modelo SVM.

Accuracy	Precision	Recall	F1-score	Matriz de confusión
0,8212	0,8387	0,7027	0,7647	[[95, 10], [22, 52]]

Tabla 13. Resultados del modelo SVM en el conjunto de prueba.




Figura 5. Matriz de confusión del modelo SVM.

SVM presenta el mejor equilibrio global entre los cuatro modelos: Accuracy = 0,8212, Precision = 0,8387 y F1-score = 0,7647, todos los máximos del conjunto evaluado. Su matriz contiene 95 verdaderos negativos, 52 verdaderos positivos, 10 falsos positivos y 22 falsos negativos. La principal desventaja frente al árbol es su menor interpretabilidad.

VIII. Modelo Naïve Bayes

Naïve Bayes estima probabilidades de clase mediante el teorema de Bayes y el supuesto de independencia condicional entre predictores. Se utiliza GaussianNB, que modela los predictores continuos mediante distribuciones gaussianas por clase (scikit-learn Developers, s. f.-d).

Parámetro / supuesto	Valor	Interpretación
Variante	GaussianNB	Modelo gaussiano para predictores continuos.
priors	No especificado	Las probabilidades previas se estiman desde los datos.
var_smoothing	Valor por defecto	Estabiliza el cálculo de varianzas.
Datos	X_train / X_test	No se aplica escalamiento específico.

Tabla 14. Ficha técnica mínima del modelo Naïve Bayes.

Accuracy	Precision	Recall	F1-score	Matriz de confusión
0,7709	0,7200	0,7297	0,7248	[[84, 21], [20, 54]]

Tabla 15. Resultados de Naïve Bayes en el conjunto de prueba.




Figura 6. Matriz de confusión del modelo Naïve Bayes.

Naïve Bayes obtiene Accuracy = 0,7709 y F1-score = 0,7248. Su rasgo más destacado es el Recall = 0,7297, el más alto de los cuatro modelos: identifica 54 sobrevivientes y deja 20 falsos negativos. A cambio, produce 21 falsos positivos, más que Árbol y SVM. Es una referencia probabilística eficiente, aunque el supuesto de independencia condicional puede ser restrictivo en variables tabulares relacionadas.

IX. Evaluación preliminar de modelos de clasificación

La comparación se realiza sobre el mismo conjunto de prueba de 179 observaciones y combina métricas globales con la estructura de errores de cada matriz de confusión. Esto permite distinguir el mejor equilibrio general de un modelo que destaque en una métrica específica (Pedregosa et al., 2011).

Modelo	Accuracy	Precision	Recall	F1-score	TN	FP	FN	TP
KNN	0,6983	0,6786	0,5135	0,5846	87	18	36	38
Árbol	0,7989	0,8276	0,6486	0,7273	95	10	26	48
SVM	0,8212	0,8387	0,7027	0,7647	95	10	22	52
Naïve Bayes	0,7709	0,7200	0,7297	0,7248	84	21	20	54

Tabla 16. Comparación preliminar de métricas y errores de clasificación.




Figura 7. Comparación de Accuracy, Precision, Recall y F1-score.

9.1 Interpretación comparativa

SVM lidera Accuracy, Precision y F1-score, por lo que constituye la alternativa con mejor equilibrio global en esta partición. Naïve Bayes obtiene el Recall más alto, lo cual puede ser relevante si el costo prioritario fuera omitir sobrevivientes reales. El Árbol de Decisión ofrece un desempeño cercano a los mejores con mayor interpretabilidad. KNN funciona como línea base, pero su Recall bajo y la ausencia de escalamiento limitan su resultado actual.

Modelo	Fortalezas	Limitaciones	Lectura preliminar
KNN	Simple, intuitivo y no paramétrico.	Bajo Recall; sensible a escala; se ejecutó sin escalar.	Línea base; requiere comparar con versión escalada.
Árbol	Buena Precision e interpretabilidad.	Recall moderado; sensibilidad a profundidad.	Alternativa explicable y competitiva.
SVM	Mejor Accuracy, Precision y F1; pocos FP.	Menor interpretabilidad; depende de escalamiento y parámetros.	Mejor equilibrio global en esta ejecución.
Naïve Bayes	Mayor Recall; rápido y probabilístico.	Más FP; supuesto de independencia restrictivo.	Útil si se prioriza reducir falsos negativos.

Tabla 17. Fortalezas, limitaciones e implicancias analíticas.

Estos resultados son preliminares porque provienen de una única partición entrenamiento/prueba y de configuraciones mínimas. No se realizó validación cruzada ni búsqueda sistemática de hiperparámetros en esta Formativa, por lo que no corresponde afirmar superioridad definitiva ni generalizar más allá del experimento ejecutado.

X. Conclusiones

La Formativa 3 permitió construir un flujo completo de clasificación supervisada sobre Titanic: descripción del dataset, revisión de calidad, preparación de datos, definición de una partición 80/20, implementación de cuatro algoritmos y evaluación mediante métricas y matrices de confusión. La coherencia entre código, resultados e interpretación permite utilizar esta evidencia como base para la continuidad del proyecto.

Entre los cuatro modelos evaluados, SVM entrega el mejor equilibrio preliminar: Accuracy = 0,8212, Precision = 0,8387 y F1-score = 0,7647. Naïve Bayes obtiene el mayor Recall (0,7297), por lo que puede resultar preferible si el objetivo operativo priorizara reducir falsos negativos. El Árbol de Decisión mantiene valor por su interpretabilidad, mientras que el desempeño de KNN debe interpretarse considerando que fue evaluado sin escalamiento.

Los resultados obtenidos corresponden a la configuración y partición de datos utilizadas en esta etapa, por lo que las diferencias de desempeño observadas deben interpretarse dentro de este contexto.

XI. XI. Uso de fuentes, citación y referencias

Las decisiones conceptuales, metodológicas y técnicas del informe se sustentan en material docente, documentación técnica oficial y literatura académica. Las referencias siguientes corresponden a fuentes utilizadas y citadas en el desarrollo, en formato APA 7.ª edición.

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- scikit-learn Developers. (s. f.-a). `sklearn.neighbors.KNeighborsClassifier`. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>
- scikit-learn Developers. (s. f.-b). `sklearn.tree.DecisionTreeClassifier`. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>
- scikit-learn Developers. (s. f.-c). `sklearn.svm.SVC`. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>
- scikit-learn Developers. (s. f.-d). `sklearn.naive_bayes.GaussianNB`. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html
- scikit-learn Developers. (s. f.-e). `sklearn.preprocessing.StandardScaler`. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>
- Universidad Andrés Bello. (2026a). MCDI504 Machine Learning I: Evaluación Formativa 3 – Avance del Proyecto, Fase 3: Desarrollo del Proyecto [Instrucciones de actividad].
- Universidad Andrés Bello. (2026b). fase_3_avance_semana_3_formativa [Cuaderno Jupyter de apoyo docente, MCDI504 Machine Learning I].
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

XII. Anexos

Anexo A. Detalle de las matrices de confusión

Modelo / clase real	Pred. No sobrevivió	Pred. Sobrevivió
KNN — Real no sobrevivió	87	18
KNN — Real sobrevivió	36	38
Árbol — Real no sobrevivió	95	10
Árbol — Real sobrevivió	26	48
SVM — Real no sobrevivió	95	10
SVM — Real sobrevivió	22	52
Naïve Bayes — Real no sobrevivió	84	21
Naïve Bayes — Real sobrevivió	20	54

Tabla 18. Resultados complementarios derivados de las cuatro matrices de confusión.

Anexo B. Fragmentos esenciales del pipeline

```

X = titanic_df_processed.drop('survived', axis=1)
y = titanic_df_processed['survived']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20, random_state=42)
knn_model = KNeighborsClassifier(n_neighbors=5, metric='minkowski', p=2)
dtree_model = DecisionTreeClassifier(random_state=42, max_depth=5, criterion='gini')
scaler = StandardScaler(); X_train_scaled = scaler.fit_transform(X_train)
svm_model = SVC(kernel='rbf', C=1, random_state=42)
nb_model = GaussianNB()

```