



MCDI504

MACHINE LEARNING I

INFORME FINAL DEL PROYECTO - FASE 4: EVALUACIÓN Y VALIDACIÓN DEL MODELO

Integrantes: Enzo Pinilla, Claudio Alarcón, Luis Rodrigo Espinoza

Curso: MCDI504 - Machine Learning I

Evaluación: Semana 04. Sumativa 3: Informe final del proyecto Fase 4

Docente: David Ruede Zúñiga

Grupo: 2

Fecha de entrega: 30 de agosto de 2026

Repositorio: github.com/sauriomac/MCDI504_MACHINE_LEARNING_1_GRUPO_2

I. Tabla de contenido

<i>I. Tabla de contenido</i>	2
<i>II. Evaluación del desempeño del modelo</i>	3
<i>III. Reporte tabulado e interpretación de métricas del modelo</i>	4
<i>IV. Matriz de confusión y métricas de clasificación</i>	4
<i>V. Interpretación del desempeño del modelo</i>	6
5.1 Falsos positivos y falsos negativos	6
5.2 Fortalezas y limitaciones	6
<i>VI. Interpretación para toma de decisiones</i>	7
<i>VII. Notebook y trazabilidad del proceso de evaluación del modelo</i>	7
<i>VIII. Conclusiones técnicas del desempeño del modelo</i>	8
<i>IX. Reporte tabulado e interpretación de estabilidad de métricas</i>	8
<i>X. Justificación de técnica de validación</i>	10
<i>XI. Coherencia metodológica de validación</i>	10
<i>XII. Notebook y trazabilidad del proceso de validación</i>	11
<i>XIII. Conclusiones técnicas del proceso de validación</i>	11
<i>XIV. Uso de fuentes, citación y referencias</i>	12
<i>XV. Anexos</i>	12
Anexo A. Resultados completos Hold-Out	12
Anexo B. Resultados completos K-Fold	12
Anexo D. Estructura del repositorio y reproducibilidad	13

II. Evaluación del desempeño del modelo

El caso ABP utiliza el dataset Titanic para predecir la supervivencia de pasajeros a partir de variables demográficas y de viaje. La variable objetivo es survived y la clase positiva utilizada para precision, recall y F1-score es sobrevivió (1). El dataset contiene 891 observaciones y 15 columnas; para modelar se utilizan pclass, sex, age, sibsp, parch, fare y embarked. La clase no sobrevivió representa 61,62% de los registros y la clase sobrevivió 38,38%, por lo que existe un desbalance moderado que aconseja interpretar accuracy junto con métricas de la clase positiva (Ruete, 2026; James et al., 2021).

Elemento	Decisión aplicada
Problema analítico	Clasificación binaria: predecir si un pasajero sobrevivió.
Variable objetivo	survived: 0 = no sobrevivió; 1 = sobrevivió.
Clase positiva	Sobrevivió (1).
Predictores	pclass, sex, age, sibsp, parch, fare, embarked.
Hold-Out	80/20 estratificado; 712 entrenamiento y 179 prueba; random_state=42.
Modelos evaluados	MLP (100,), MLP (100,50) y MLP (100,50,25).
Modelo validado	MLP de una capa (100,) con StratifiedKFold k=5.

El pipeline de evaluación se construyó para impedir fuga de información: imputación, codificación y escalamiento se ajustan solo con datos de entrenamiento. En validación cruzada el pipeline completo se vuelve a ajustar dentro de cada fold. Esta decisión aplica la regla metodológica indicada en el material docente: todo preprocesamiento que aprende parámetros debe estimarse dentro del entrenamiento o de cada fold (Ruete, 2026).

Figura 1. Distribución de clases en el dataset Titanic




Figura 1. Distribución de la variable objetivo survived.

III. Reporte tabulado e interpretación de métricas del modelo

Las métricas se calculan sobre el mismo conjunto de prueba estratificado. Accuracy resume el porcentaje total de clasificaciones correctas; precision mide la confiabilidad de las predicciones positivas; recall mide la proporción de sobrevivientes reales detectados; y F1-score equilibra precision y recall. Estas métricas responden a preguntas distintas y deben leerse conjuntamente (Ruete, 2026; scikit-learn Developers, 2026a).

Modelo	Accuracy	Precision	Recall	F1-score
MLP 1 capa oculta	0,7821	0,7679	0,6232	0,6880
MLP 2 capas ocultas	0,8156	0,7903	0,7101	0,7481
MLP 3 capas ocultas	0,8045	0,7931	0,6667	0,7244

El MLP de dos capas obtiene el mayor accuracy (0,8156), recall (0,7101) y F1-score (0,7481), lo que lo convierte en el candidato preliminar con mejor equilibrio en esta partición. El MLP de tres capas obtiene la mayor precision (0,7931), aunque sacrifica recall respecto del modelo de dos capas. El MLP de una capa presenta el desempeño puntual más bajo de las tres arquitecturas, pero se conserva como modelo de referencia para la validación cruzada exigida por la fase.




Figura 2. Comparación de métricas Hold-Out de las tres arquitecturas MLP.

IV. Matriz de confusión y métricas de clasificación

Las filas de cada matriz representan la clase real y las columnas la clase predicha. Así, TN corresponde a no sobrevivientes correctamente clasificados; FP a no sobrevivientes predichos como sobrevivientes; FN a sobrevivientes omitidos; y TP a sobrevivientes correctamente identificados.

Modelo	TN	FP	FN	TP	Accuracy	Precision	Recall	F1
MLP 1 capa	97	13	26	43	0,7821	0,7679	0,6232	0,6880
MLP 2 capas	97	13	20	49	0,8156	0,7903	0,7101	0,7481
MLP 3 capas	98	12	23	46	0,8045	0,7931	0,6667	0,7244




Figura 3. Matriz de confusión - MLP de una capa oculta.




Figura 4. Matriz de confusión - MLP de dos capas ocultas.




Figura 5. Matriz de confusión - MLP de tres capas ocultas.

V. Interpretación del desempeño del modelo

5.1 Falsos positivos y falsos negativos

El MLP de dos capas reduce los falsos negativos a 20, frente a 26 del MLP de una capa y 23 del MLP de tres capas. Por ello detecta una proporción mayor de sobrevivientes reales. El MLP de tres capas produce 12 falsos positivos, uno menos que las otras dos arquitecturas, coherente con su mayor precisión.

5.2 Fortalezas y limitaciones

Arquitectura	Fortalezas	Limitaciones
MLP 1 capa	Arquitectura más simple; única validada mediante K-Fold.	Menor recall y F1 Hold-Out; 26 FN; alcanza max_iter=500 con ConvergenceWarning.
MLP 2 capas	Mayor accuracy, recall y F1; solo 20 FN.	Mayor complejidad; también alcanza max_iter=500 con ConvergenceWarning.
MLP 3 capas	Mayor precisión; 12 FP; converge en 313 iteraciones.	Recall inferior al MLP 2; mayor complejidad e interpretabilidad limitada.

Las advertencias de convergencia no invalidan automáticamente las predicciones, pero sí son una condición del experimento que impide presentar los resultados como una optimización definitiva. La documentación de MLPClassifier recomienda interpretar y ajustar parámetros de optimización según el problema; en este trabajo no se modifica max_iter después de observar prueba para evitar convertir la evaluación final en una búsqueda oportunista de hiperparámetros (scikit-learn Developers, 2026c).

VI. Interpretación para toma de decisiones

El criterio de selección depende del costo de los errores. Si interesa detectar la mayor proporción posible de la clase positiva, el MLP de dos capas es la alternativa Hold-Out más favorable por su mayor recall y menor cantidad de falsos negativos. Si el costo de declarar un positivo inexistente fuera mayor, el MLP de tres capas ofrece la mayor precisión y el menor número de falsos positivos.

Criterio de decisión	Resultado más favorable	Implicancia
Mayor desempeño global Hold-Out	MLP 2 capas - Accuracy 0,8156	Mayor proporción total de aciertos en la partición de prueba.
Mayor detección de positivos	MLP 2 capas - Recall 0,7101	Menor omisión de sobrevivientes: 20 FN.
Mayor confiabilidad del positivo	MLP 3 capas - Precision 0,7931	Menor proporción relativa de falsas alarmas; 12 FP.
Modelo con evidencia de estabilidad	MLP 1 capa - K-Fold k=5	Permite observar promedio y variación entre particiones.

El caso Titanic tiene propósito pedagógico. Por ello, estas cifras no deben trasladarse directamente a decisiones reales ni interpretarse causalmente. La utilidad del ejercicio consiste en demostrar cómo el tipo de error, la métrica prioritaria y la estabilidad condicionan una decisión basada en datos.

VII. Notebook y trazabilidad del proceso de evaluación del modelo

El notebook definitivo es `notebooks/F4\_Evaluacion\_Sumativa.ipynb`. Fue ejecutado de principio a fin y genera las tablas y figuras utilizadas en este informe. El repositorio incluye además el dataset local, los requisitos de software y un README actualizado para reproducir la ejecución.

Etapas	Evidencia técnica	Resultado trazable
Carga de datos	data/titanic.csv con fallback público	891 x 15.
Partición	train_test_split(..., stratify=y, random_state=42)	712 entrenamiento / 179 prueba.
Preprocesamiento	ColumnTransformer + Pipeline	Imputación, OneHotEncoder y StandardScaler sin fuga.
Evaluación	accuracy_score, precision_score, recall_score, f1_score, confusion_matrix	Tablas de Secciones III-IV.
Figuras	figures/fase4_evaluacion/	Distribución, métricas, matrices y K-Fold.

Fragmento central de la estrategia de evaluación:

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42
)
pipeline = Pipeline([
    ('preprocesamiento', preprocesador),
    ('mlp', MLPClassifier(..., random_state=42))
])
```

VIII. Conclusiones técnicas del desempeño del modelo

1. El MLP de dos capas ocultas muestra el mejor equilibrio Hold-Out, con Accuracy 0,8156, Recall 0,7101 y F1-score 0,7481.
2. El MLP de tres capas alcanza la mayor Precision (0,7931) y converge en 313 iteraciones, pero presenta un recall menor que el MLP de dos capas.
3. El MLP de una capa es más simple y es el modelo seleccionado por la pauta para estudiar estabilidad mediante K-Fold, no porque sea el mejor resultado puntual.
4. Los falsos negativos siguen siendo relevantes en las tres arquitecturas y deben incorporarse a cualquier interpretación orientada a decisiones.
5. Como mejoras futuras se propone estudiar convergencia, early stopping, regularización, calibración/ajuste de umbral y métricas ROC-AUC y precision-recall, manteniendo la evaluación independiente.

IX. Reporte tabulado e interpretación de estabilidad de métricas

La estabilidad se evalúa con StratifiedKFold de cinco particiones sobre el conjunto de entrenamiento. En cada fold se construye y ajusta desde cero el pipeline completo. La estratificación mantiene aproximadamente la proporción de clases en cada partición y la repetición permite estimar variabilidad, no solo un valor puntual (Universidad Andrés Bello, 2026a; scikit-learn Developers, 2026b).

Fold	Accuracy	Precision	Recall	F1-score
1	0,8601	0,8571	0,7636	0,8077
2	0,7972	0,7826	0,6545	0,7129
3	0,8592	0,9070	0,7091	0,7959
4	0,8099	0,7368	0,7778	0,7568
5	0,8028	0,8095	0,6296	0,7083

Resumen	Accuracy	Precision	Recall	F1-score
Promedio	0,8258	0,8186	0,7069	0,7563
Desviación estándar	0,0312	0,0659	0,0651	0,0458
Coefficiente de variación	0,0378	0,0805	0,0921	0,0606

La matriz agregada de validación es $[[395, 44], [80, 193]]$. De 273 positivos reales, 80 quedan como falsos negativos, equivalentes al 29,30%. El accuracy presenta la menor variabilidad relativa; recall exhibe la mayor, de modo que la capacidad de detectar sobrevivientes es menos estable que el acierto global.




Figura 6. Accuracy del MLP de una capa en cada fold.




Figura 7. Promedio y desviación estándar de métricas en K-Fold.

Los cinco folds alcanzan `max_iter=500` con `ConvergenceWarning`. Por tanto, la estabilidad estimada describe el comportamiento del experimento configurado, pero debe interpretarse como evidencia condicionada por la convergencia incompleta.

X. Justificación de técnica de validación

Se utiliza K-Fold estratificado con $k=5$ porque el conjunto de entrenamiento tiene 712 observaciones y se requiere equilibrar costo computacional con una estimación de variabilidad. La pauta solicita relacionar explícitamente tamaño del dataset, costo y estabilidad; cinco folds cumplen esa finalidad sin multiplicar el entrenamiento hasta el extremo de Leave-One-Out (Universidad Andrés Bello, 2026b).

Técnica	Costo aproximado	Ventaja	Limitación / decisión
Hold-Out	1 entrenamiento	Rápido y simple.	Depende de una sola partición; se usa como evaluación puntual.
Stratified K-Fold $k=5$	5 entrenamientos	Entrega promedio y variabilidad; mantiene proporción de clases.	Costo moderado; técnica seleccionada.
Leave-One-Out	~712 entrenamientos	Usa casi todos los datos para entrenar en cada iteración.	Costo alto para un MLP; no se justifica en esta fase.

K-Fold no se interpreta como un mecanismo que "mejora" la métrica. Su valor es estimar cuán sensible es el resultado a distintas particiones. Esta distinción evita comparar el promedio de K-Fold como si fuera una cuarta arquitectura Hold-Out.

XI. Coherencia metodológica de validación

La metodología es coherente porque el problema, las métricas, la clase positiva, el preprocesamiento y la validación se mantienen alineados. En particular, el ajuste de imputadores, codificador y escalador ocurre dentro del pipeline y, durante K-Fold, dentro de cada fold. De este modo, las observaciones de validación no influyen en medianas, modas, categorías o parámetros de escalamiento aprendidos durante entrenamiento.

Dimensión	Decisión	Coherencia
Problema	Clasificación binaria de survived	Matriz de confusión y métricas binarias son pertinentes.
Clase positiva	Sobrevivió = 1	Precision, recall y F1 se interpretan sobre el evento de interés.
Partición	80/20 estratificada	Evita cambios artificiales de proporción de clases.
Preprocesamiento	Pipeline/ColumnTransformer	Previene data leakage.
Validación	StratifiedKFold $k=5$	Permite estimar promedio y dispersión con costo razonable.
Reproducibilidad	random_state=42	Permite repetir particiones y entrenamiento bajo el mismo protocolo.

Esta corrección metodológica es especialmente importante porque el material docente señala que el preprocesamiento que aprende parámetros debe ajustarse dentro del entrenamiento o de cada fold. Por ello, las cifras de la presente Sumativa utilizan el protocolo metodológico final con el preprocesamiento contenido dentro del pipeline, evitando que la información del fold de validación participe en el ajuste de imputadores, codificador o escalador.

XII. Notebook y trazabilidad del proceso de validación

El bloque de validación utiliza StratifiedKFold y crea un pipeline nuevo para cada partición. A partir de las predicciones de validación se calculan las cuatro métricas, la matriz de confusión por fold y una matriz agregada. El notebook conserva las salidas ejecutadas y genera las figuras utilizadas en este informe.

```
skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
for fold, (idx_tr, idx_val) in enumerate(skf.split(X_train, y_train), start=1):
    pipe_fold = construir_pipeline((100,))
    resultados, cm, pred = evaluar_pipeline(
        pipe_fold,
        X_train.iloc[idx_tr], y_train.iloc[idx_tr],
        X_train.iloc[idx_val], y_train.iloc[idx_val]
    )
```

Evidencia de validación	Resultado
Número de folds	5
Accuracy promedio	0,8258
Accuracy DE	0,0312
F1 promedio	0,7563
F1 DE	0,0458
Matriz agregada	[[395, 44], [80, 193]]
Folds con ConvergenceWarning	5 de 5

XIII. Conclusiones técnicas del proceso de validación

1. StratifiedKFold k=5 permite evaluar el MLP de una capa en cinco particiones manteniendo proporciones de clase comparables.
2. El Accuracy promedio de 0,8258 con DE 0,0312 sugiere estabilidad razonable del desempeño global; Precision y Recall presentan mayor variabilidad.
3. La matriz agregada evidencia 80 falsos negativos, por lo que una lectura exclusivamente basada en Accuracy sería incompleta.
4. La técnica es pertinente para 712 observaciones porque combina cinco entrenamientos con información de variabilidad; Leave-One-Out elevaría el costo a aproximadamente 712 entrenamientos.
5. La convergencia incompleta en los cinco folds es la principal limitación técnica y debe abordarse en una iteración futura sin utilizar el conjunto de prueba para escoger ajustes.

XIV. Uso de fuentes, citación y referencias

El informe integra material docente, instrucciones institucionales, documentación técnica oficial y bibliografía académica. Las referencias se presentan en formato APA 7.^a edición y se utilizan en el desarrollo para sustentar definiciones de métricas, prevención de data leakage, validación y características del clasificador.

- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2021). An introduction to statistical learning: With applications in R (2nd ed.). Springer.
- Ruete, D. (2026). Fase 4: métricas y técnicas de evaluación [Presentación de clase]. Universidad Andrés Bello.
- Universidad Andrés Bello. (2026a). Avance del proyecto - Fase 4: Evaluación y validación del modelo [Instrucciones de evaluación Formativa 4].
- Universidad Andrés Bello. (2026b). Semana 04. Sumativa 3: Informe final del proyecto Fase 4 - Evaluación y validación del modelo [Instrucciones y rúbrica].
- scikit-learn Developers. (2026a). Metrics and scoring: Quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html
- scikit-learn Developers. (2026b). Cross-validation: Evaluating estimator performance. https://scikit-learn.org/stable/modules/cross_validation.html
- scikit-learn Developers. (2026c). MLPClassifier. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html

XV. Anexos

Anexo A. Resultados completos Hold-Out

Modelo	TN	FP	FN	TP	Acc.	Prec.	Recall	F1	Iter.	Conv.
MLP 1 capa	97	13	26	43	0,7821	0,7679	0,6232	0,6880	500	Sí
MLP 2 capas	97	13	20	49	0,8156	0,7903	0,7101	0,7481	500	Sí
MLP 3 capas	98	12	23	46	0,8045	0,7931	0,6667	0,7244	313	No

Anexo B. Resultados completos K-Fold

Fold	Acc.	Prec.	Recall	F1	Iter.	Conv.
1	0,8601	0,8571	0,7636	0,8077	500	Sí
2	0,7972	0,7826	0,6545	0,7129	500	Sí
3	0,8592	0,9070	0,7091	0,7959	500	Sí
4	0,8099	0,7368	0,7778	0,7568	500	Sí
5	0,8028	0,8095	0,6296	0,7083	500	Sí

Anexo D. Estructura del repositorio y reproducibilidad

- README.md
- requirements.txt
- CHECKLIST_RUBRICA.md
- data/
 - titanic.csv
- README_datos.md
- notebooks/
 - F4_Evaluacion_Sumativa.ipynb
- figures/
 - fase4_evaluacion/
- docs/
 - MCDI504_S4_2_GRUPO2.docx
 - MCDI504_S4_2_GRUPO2.pdf